

Nombre de la universidad

Facultad o escuela

Título de la tesis doctoral

Autor: Nombre del autor

Director: Nombre del director

Tesis presentada para la obtención del grado de

Doctor en [Área o Programa]

Ciudad, País

mayo de 2026

Dedicatoria

Escribe aquí tu dedicatoria.

Agradecimientos

Escribe aquí tus agradecimientos.

Resumen

Redacta aquí un resumen estructurado de tu tesis, incluyendo problema, objetivo, metodología, resultados principales y conclusiones.

Abstract

Write here the English abstract of your dissertation, including problem, objective, methodology, main results, and conclusions.

Índice general

Dedicatoria	I
Agradecimientos	II
Resumen	III
Abstract	IV
1. Introducción	1
1.1. Contexto y Relevancia del Problema	1
1.2. Planteamiento del Problema	3
1.3. Objetivos de la Investigación	5
1.4. Hipótesis	6
1.5. Justificación	6
1.6. Estructura del Documento	8
2. Revisión Sistemática de Literatura: resultados de la extracción y síntesis temática	9
2.1. Delimitación y Propósito de la Revisión	9
2.2. Diseño del Protocolo de Búsqueda y Cribado	10
2.2.1. Fuentes de Información y Estrategia de Búsqueda	10
2.2.2. Criterios de Elegibilidad	10

2.2.3. Flujo de Selección	11
2.3. Evaluación de la Calidad Metodológica del Corpus Primario	11
2.3.1. Instrumento de Evaluación	11
2.3.2. Distribución de Puntuaciones	12
2.4. Caracterización del Corpus Empírico ($n = 190$)	12
2.4.1. Entornos de Simulación y Validación	12
2.4.2. Algoritmos de RL y Arquitecturas Dominantes	13
2.4.3. Transparencia y Reproducibilidad	13
2.5. Resultados de la Meta-Revisión de Revisiones Existentes	14
2.5.1. Corpus de Revisiones Identificadas	14
2.5.2. Revisiones de alta relevancia (Grupo A)	14
2.5.3. Revisiones de relevancia media (Grupo B)	15
2.5.4. Síntesis de la Meta-Revisión	16
2.6. Síntesis de la Evidencia por Pregunta de Investigación ($n = 190$)	16
2.7. Brechas del Estado del Arte y Posicionamiento de la Tesis	17
2.8. Síntesis del Capítulo	19
3. Marco Teórico	20
3.1. Fundamentos del Sistema o Modelo Propuesto	20
3.2. Modelado Matemático del Problema	21
3.2.1. Formulación MDP para Control Semafórico Urbano	21
3.3. Modelos de Aprendizaje o Predicción	22
3.3.1. Arquitectura Principal: Vine Copulas para Generación de Escenarios . . .	22
3.4. Aprendizaje por Refuerzo, Optimización o Control	23
3.4.1. Formulación del Problema Risk-Aware	23
3.4.2. Algoritmo Principal: PPO/SAC con Penalización CVaR	24

3.5. Modelado de Dependencias o Incertidumbre	24
3.5.1. Estructura del Modelo Probabilístico o Estadístico	24
3.6. Equidad, Robustez o Criterios Éticos	25
3.6.1. Métricas de Evaluación Ética o de Robustez	25
3.6.2. Función de Recompensa Ajustada (Gini + CVaR)	25
3.7. Modelos de Comportamiento o Escenario	26
3.7.1. Perfil 1: Conducción Anómala y Desobediencia Vial	26
3.7.2. Perfil 2: Eventos Exógenos y Fallos de Infraestructura	26
3.8. Modelo Híbrido de Optimización o Integración	26
3.9. Algoritmo de Entrenamiento Unificado	27
3.10. Conclusión del Marco Teórico	27
4. Metodología	29
4.1. Diseño General del Sistema	29
4.2. Pipeline de Datos	30
4.2.1. Fuentes de Datos y Entorno Experimental	30
4.2.2. Preprocesamiento y Validación PRISMA (Representación del Estado)	31
4.3. Implementación del Modelo Híbrido	32
4.3.1. Entrenamiento del Módulo de Copulas	32
4.3.2. Configuración del Agente RL Ligero	33
4.3.3. Integración del Módulo de Transferencia Interregional	34
4.4. Diseño Experimental	35
4.4.1. Escenarios de Validación	35
4.4.2. Protocolo de Entrenamiento y Paralelización	36
4.5. Métricas de Evaluación	36
4.5.1. Rendimiento Técnico	36

4.5.2. Equidad Algorítmica y Robustez	37
4.6. Herramientas y Configuración de Software	37
4.7. Diagrama de Flujo del Sistema	38
4.8. Protocolo de Validación Estadística	38
4.9. Consideraciones Éticas	39
4.10. Conclusión Metodológica	40
5. Resultados y Discusión	41
5.1. Configuración Experimental	41
5.2. Evaluación del Módulo de Generación de Escenarios	41
5.3. Evaluación del Módulo de Decisión o Control	41
5.4. Evaluación del Módulo de Equidad o Robustez	41
5.5. Comparativa con Modelos Tradicionales	41
5.6. Análisis Estadístico y Robustez	42
5.7. Discusión de Resultados	42
5.8. Limitaciones	42
5.9. Conclusión del Capítulo	42
6. Discusión	43
6.1. Interpretación de los Resultados Clave	43
6.2. Comparación con el Estado del Arte	43
6.2.1. Ventajas sobre Métodos Existentes	43
6.2.2. Limitaciones Persistentes	43
6.3. Implicaciones Teóricas y Prácticas	43
6.3.1. Contribuciones al Campo	43
6.3.2. Impacto Aplicado o Socioeconómico	43

6.4. Limitaciones y Sesgos	44
6.4.1. Dependencia de Datos o Supuestos	44
6.4.2. Sesgos en Perfiles, Muestras o Anotaciones	44
6.5. Lecciones Aprendidas	44
6.6. Recomendaciones para Políticas Públicas o Implementación	44
6.7. Futuras Líneas de Investigación	44
6.8. Conclusión Final	44
7. Conclusiones y Trabajo Futuro	45
7.1. Síntesis de Contribuciones Clave	45
7.2. Cumplimiento de Objetivos e Hipótesis	45
7.3. Limitaciones y Desafíos	45
7.4. Recomendaciones para Implementación Práctica	45
7.5. Trabajo Futuro	45
7.6. Reflexión Final	46
A. Anexos	51
A.1. Protocolo de Búsqueda y Cadenas de Consulta	51
A.2. Matriz de Extracción SLR (Corpus Primario)	52
A.3. Diagrama PRISMA 2020 (Fase 1 y Fase 2)	53
A.4. Hiperparámetros y Configuración de Entrenamiento	54
A.5. Código Fuente y Repositorio Complementario	55

Índice de figuras

Índice de cuadros

2.1. Resumen cuantitativo del flujo de selección en las dos fases de la revisión	11
2.2. Distribución de calidad metodológica del corpus primario ($n = 190$)	12
2.3. Plataformas de simulación predominantes en el corpus primario ($n = 190$)	13
2.4. Revisiones de alta relevancia (Grupo A, $n = 16$)	15
2.5. Revisiones de relevancia media (Grupo B, $n = 12$)	16
2.6. Cobertura temática del corpus primario según pregunta de investigación ($n = 190$)	17

Capítulo 1

Introducción

1.1. Contexto y Relevancia del Problema

La gestión del tráfico urbano constituye un problema de decisión secuencial de alta complejidad, en el que interactúan demanda no estacionaria, restricciones de infraestructura, heterogeneidad modal, eventos exógenos y comportamientos humanos difícilmente reducibles a patrones regulares. En este contexto, la congestión no debe entenderse únicamente como un fenómeno de ineficiencia operativa, sino como una manifestación sistémica de desequilibrios entre capacidad vial, control, información disponible y variabilidad conductual. Sus efectos trascienden el aumento del tiempo de viaje: degradan la productividad urbana, incrementan el consumo energético, amplifican emisiones contaminantes y distribuyen de manera desigual los costos de movilidad entre distintos grupos y territorios.

En la última década, el control semafórico basado en Aprendizaje por Refuerzo (RL), y particularmente sus variantes profundas y multiagente, ha sido propuesto como una alternativa prometedora a los esquemas de tiempo fijo o actuados. Su atractivo reside en la posibilidad de aprender políticas adaptativas a partir de la interacción continua con el entorno, optimizando señales en tiempo real bajo criterios como demora, presión o longitud de cola. Sin embargo, el rendimiento reportado por una parte importante del estado del arte se sostiene sobre una condición metodológica que rara vez se problematiza con la profundidad necesaria: la mayor parte de los experimentos se diseñan y valida sobre entornos simulados cuya física vehicular, topología de red y supuestos conductuales responden predominantemente a contextos idealizados, altamente instrumentados y cercanos a realidades eurocéntricas o norteamericanas.

Esta observación es especialmente crítica para América Latina. En muchas ciudades de la región, la operación del tráfico está determinada por redes viales irregulares, intersecciones con geometrías no canónicas, cobertura sensorial incompleta, mantenimiento heterogéneo de la infraestructura y una cultura vial caracterizada por alta variabilidad conductual. Fenómenos como la invasión de intersecciones, el bloqueo de caja, el uso oportunista de brechas, la desobediencia parcial de fases, los tiempos de reacción atípicos y la interferencia recurrente entre modos no son

meras desviaciones marginales respecto del régimen nominal; constituyen patrones operativos recurrentes que alteran la propagación de colas, la estabilidad de las fases y la formación de bloqueos aguas arriba. Por ello, tratarlos como simple ruido estocástico o eliminarlos durante la calibración produce un sesgo de representación que deteriora la validez externa de los modelos de IA aplicados al control semafórico.

El problema de fondo no es solo la insuficiencia de datos, sino un sesgo estructural de simulación. Simuladores de microtráfico ampliamente utilizados, como SUMO, permiten una calibración detallada y son herramientas indispensables para investigación reproducible; no obstante, sus configuraciones por defecto descansan sobre modelos de seguimiento vehicular, aceptación de brechas y obediencia semafórica que privilegian regularidad cinemática y cumplimiento normativo. Cuando estos supuestos no se tensionan explícitamente, el agente de RL tiende a sobreajustarse a entornos excesivamente ordenados y, en consecuencia, aprende políticas eficaces para tráfico disciplinado, pero frágiles frente a contextos donde la incertidumbre operacional surge precisamente de la interacción entre infraestructura limitada y comportamiento humano no ideal. En términos metodológicos, ello implica un *overfitting* no solo al simulador, sino a una ontología vial implícita que no representa adecuadamente la realidad urbana latinoamericana.

Desde esta perspectiva, la presente tesis parte de una premisa distinta: los comportamientos viales adversos no deben excluirse del modelo ni describirse en clave moral, sino incorporarse como anomalías estructuradas relevantes para la dinámica del sistema. Esto significa parametrizar probabilísticamente dependencias entre demanda, incidentes, incumplimientos operativos, ruido sensorial y perturbaciones contextuales, de manera que el entorno de entrenamiento no reproduzca únicamente condiciones medias, sino también perfiles de estrés plausibles. Bajo este enfoque, la inteligencia artificial no se concibe como un mecanismo que corrige conductas individuales, sino como un sistema de gestión de riesgo sistémico capaz de operar de forma robusta cuando la red se aproxima a estados de congestión crítica, *spillover* o pérdida de equidad distributiva.

A partir de la revisión sistemática preliminar realizada sobre literatura reciente en control semafórico inteligente, se identifican cinco limitaciones que restringen la transferencia de los avances actuales a contextos urbanos reales y, en particular, a escenarios latinoamericanos:

1. **Sesgo de simulación y validez externa limitada:** gran parte de los modelos se entrena en entornos con obediencia vehicular cuasi perfecta, sensorica abundante y topologías regulares, lo que dificulta extrapolar los resultados a redes urbanas con mayor fricción operacional.
2. **Explicabilidad insuficiente:** los enfoques de mayor rendimiento suelen depender de arquitecturas opacas, lo que dificulta auditar por qué una política falla o se vuelve inestable ante eventos no nominales.
3. **Robustez entendida solo como rendimiento promedio:** numerosos trabajos optimizan demora o throughput medios, pero modelan de forma débil las pérdidas de cola, el riesgo de *spillover* y la degradación extrema del servicio.

4. **Equidad tratada como objetivo secundario:** la distribución de demoras entre movimientos, accesos o grupos modales suele quedar subordinada a la eficiencia agregada, aun cuando esa distribución condiciona la legitimidad operativa del sistema.
5. **Dependencia de configuraciones computacionales poco transferibles:** los resultados más competitivos suelen apoyarse en configuraciones de entrenamiento e inferencia difíciles de desplegar en infraestructura urbana con recursos restringidos.

En consecuencia, la relevancia de esta investigación no radica únicamente en mejorar métricas clásicas de tráfico, sino en replantear el problema del control semafórico adaptativo bajo una noción más realista de entorno: una red urbana donde la incertidumbre, la fricción conductual y la heterogeneidad infraestructural son condiciones constitutivas del sistema y no perturbaciones excepcionales. Esta reformulación exige un marco metodológico que combine aprendizaje por refuerzo, modelado probabilístico de dependencias, optimización sensible al riesgo y métricas explícitas de equidad distributiva.

1.2. Planteamiento del Problema

El problema científico central de esta tesis puede formularse en los siguientes términos: existe una brecha sustantiva entre el desempeño reportado por los sistemas de control semafórico basados en RL dentro de entornos simulados convencionales y su capacidad real para operar de manera robusta, interpretable y socialmente aceptable en redes urbanas caracterizadas por observación incompleta, infraestructura heterogénea y alta variabilidad conductual. Dicha brecha es especialmente relevante en ciudades latinoamericanas, donde la cultura vial no puede modelarse como una perturbación residual de baja probabilidad, sino como un conjunto de anomalías recurrentes que alteran estructuralmente la dinámica del flujo.

En este contexto, el problema no consiste solamente en minimizar demoras promedio. Desde una perspectiva de control, el desafío es aprender políticas que mantengan estabilidad operacional cuando emergen colas de alta severidad, bloqueos de intersección, pérdida de coordinación entre nodos vecinos y degradación desigual del servicio entre movimientos competidores. En otras palabras, el objetivo es evitar que una mejora agregada en eficiencia esconda una transferencia local del riesgo hacia accesos secundarios, corredores vulnerables o zonas donde el spillback puede propagarse a la red adyacente.

Bajo esta formulación, la tesis adopta una lectura no punitiva del problema. El sistema propuesto no busca *corregir* ni *sancionar* comportamientos individuales, sino absorber sus efectos sistémicos mediante una política de control resiliente. Para ello, los comportamientos adversos —como invasión de intersecciones, bloqueo de caja, tiempos de reacción atípicos, pérdidas sensoriales o incrementos súbitos de demanda— se modelan como anomalías estructuradas con dependencias estadísticas explícitas. El uso de *Vine Copulas* responde precisamente a esta necesidad: representar interacciones no lineales entre variables operativas y contextuales para inyectar en

simulación escenarios de estrés más próximos a la dinámica real que aquellos generados bajo supuestos gaussianos o ruido independiente.

Sobre esta base, el problema central de investigación se expresa así:

¿Cómo diseñar un framework de control semafórico basado en Aprendizaje por Refuerzo que, en presencia de anomalías estructuradas propias de contextos urbanos reales y particularmente latinoamericanos, aprenda políticas interpretables, computacionalmente viables y resilientes al riesgo sistémico, minimizando simultáneamente el colapso operacional extremo y la degradación de la equidad distributiva?

Para operacionalizar esta pregunta general, el problema se descompone en cinco dimensiones analíticas:

Dimensión	Problema específico	Pregunta de investigación
D1: Representación probabilística	Las perturbaciones operativas suelen modelarse como ruido independiente o escenarios ad hoc, sin capturar dependencias reales entre demanda, incidentes y comportamiento vial.	¿Cómo modelar anomalías estructuradas de forma interpretable y estadísticamente consistente para generar perfiles de estrés realistas?
D2: Riesgo sistémico	La optimización basada en esperanza favorece políticas eficientes en promedio, pero vulnerables ante colas extremas, spillback y pérdida de estabilidad local.	¿Cómo incorporar medidas de riesgo de cola, como CVaR, para aprender políticas resistentes a episodios operacionales severos?
D3: Equidad distributiva	La minimización de demora agregada puede concentrar sistemáticamente el costo de congestión sobre ciertos movimientos, accesos o grupos modales.	¿Cómo integrar el índice de Gini en la función objetivo para evitar el colapso de la equidad bajo estrés?
D4: Transferibilidad y viabilidad	Muchos enfoques dependen de arquitecturas y requisitos computacionales difíciles de desplegar fuera de laboratorios o grandes ciudades altamente instrumentadas.	¿Cómo diseñar una solución metodológicamente sólida y a la vez viable para contextos con sensorica e infraestructura limitadas?

Dimensión	Problema específico	Pregunta de investigación
D5: Validez externa	Los agentes entrenados en simuladores calibrados bajo obediencia ideal presentan fragilidad cuando enfrentan culturas viales más caóticas o redes menos regulares.	¿Qué mecanismos permiten cerrar la brecha entre desempeño simulado y comportamiento esperado en entornos urbanos latinoamericanos?

El valor científico del problema reside en que ninguna de estas dimensiones es independiente de las demás. Una política puede ser eficiente, pero inaceptable si desplaza el riesgo hacia nodos vulnerables; puede ser robusta, pero impracticable si requiere infraestructura de cómputo inexistente; o puede ser explicable, pero irrelevante si se entrena sobre un universo simulado que omite la dinámica conductual real. Por ello, la tesis propone un enfoque integrado donde el modelado probabilístico con *Vine Copulas*, la optimización de riesgo con CVaR y la equidad distributiva basada en Gini operan como componentes complementarios de una misma formulación de control.

1.3. Objetivos de la Investigación

Objetivo general

Desarrollar y validar un framework de control semafórico basado en Aprendizaje por Refuerzo que sea interpretable, computacionalmente viable y robusto frente a anomalías estructuradas de tráfico, mediante la integración de modelado probabilístico con *Vine Copulas*, optimización de riesgo con CVaR y métricas de equidad distributiva basadas en el índice de Gini, con especial atención a la adaptación a contextos urbanos latinoamericanos.

Objetivos específicos

- OE1:** Construir un modelo basado en *Vine Copulas* que represente dependencias entre demanda, incidentes, perturbaciones operativas y comportamientos viales adversos, permitiendo generar escenarios de estrés realistas y auditables. (*RQ1*, *RQ5*)
- OE2:** Diseñar e implementar agentes de RL, particularmente PPO y SAC, con funciones objetivo sensibles al riesgo que incorporen penalización CVaR para reducir la probabilidad de colapso operacional extremo y propagación de spillback. (*RQ2*)
- OE3:** Integrar métricas de equidad distributiva, en particular el índice de Gini, dentro de la recompensa o función de valor, evaluando su efecto sobre la distribución de demoras y servicio entre movimientos competidores. (*RQ3*)

OE4: Analizar la viabilidad computacional y la capacidad de transferencia del framework propuesto en escenarios con sensórica limitada e infraestructura heterogénea, comparándolo con enfoques de mayor complejidad arquitectónica. (*RQ4, RQ5*)

1.4. Hipótesis

Se formulan cuatro hipótesis comprobables empíricamente que guiarán el diseño experimental de la tesis.

No.	Hipótesis	Dimensión
H1	Un modelo basado en <i>Vine Copulas</i> representa con mayor fidelidad e interpretabilidad la dependencia entre anomalías estructuradas de tráfico que enfoques generativos opacos, mejorando la generación de escenarios de estrés y la calibración en contextos con información limitada.	Representación probabilística
H2	Un controlador de RL optimizado con CVaR reduce de manera más consistente el riesgo de colapso operacional extremo y la propagación de spillback que un controlador entrenado únicamente bajo criterio de retorno esperado.	Riesgo sistémico
H3	La incorporación explícita del índice de Gini en la función objetivo mejora la distribución del servicio entre movimientos y accesos sin deteriorar de forma crítica la eficiencia global del sistema.	Equidad distributiva
H4	Un framework diseñado con estados agregados, modelado probabilístico interpretable y optimización sensible al riesgo ofrece mejor compromiso entre robustez, transferibilidad y costo computacional que enfoques basados en arquitecturas masivas entrenadas bajo supuestos de simulación idealizados.	Validez externa y viabilidad

1.5. Justificación

La justificación de esta tesis se apoya en una motivación científica, metodológica, tecnológica y territorial. En primer lugar, desde el punto de vista científico, el trabajo aborda una limitación persistente del campo: la tendencia a evaluar controladores semafóricos inteligentes sobre entornos cuya estructura de incertidumbre y comportamiento vial no representa adecuadamente las condiciones de operación de una parte sustantiva del mundo urbano. Esta brecha entre simulación y realidad no es un detalle experimental menor; compromete la validez externa de

los resultados y limita la capacidad de la disciplina para producir conocimiento transferible a contextos distintos de aquellos para los que los simuladores fueron originalmente calibrados.

En segundo lugar, la tesis está metodológicamente justificada porque propone una formulación integrada del problema que articula tres dimensiones que en la literatura suelen aparecer aisladas: dependencia probabilística, riesgo de cola y equidad distributiva. El modelado con *Vine Copulas* permite abandonar la representación simplificada de las anomalías como ruido independiente y capturar, en cambio, estructuras conjuntas entre demanda, incidentes, sensórica imperfecta y comportamiento vial. La optimización basada en CVaR introduce una noción explícita de gestión de riesgo sistémico, adecuada para un dominio donde los promedios pueden ocultar episodios críticos de congestión. Finalmente, la incorporación del índice de Gini evita que la política aprendida reduzca la demora agregada a costa de concentrar el deterioro del servicio en movimientos minoritarios o accesos periféricos. Esta integración dota al framework propuesto de un fundamento conceptual más sólido que el de enfoques centrados exclusivamente en eficiencia promedio.

En tercer lugar, la investigación posee relevancia tecnológica porque prioriza soluciones potencialmente desplegables en infraestructura urbana con recursos restringidos. En muchas ciudades latinoamericanas, la digitalización del control de tráfico avanza de manera desigual, con hardware heterogéneo, sensórica incompleta y restricciones presupuestarias que impiden adoptar arquitecturas de gran escala sin una fuerte adaptación local. En este escenario, una contribución doctoral de alto valor no es aquella que maximiza rendimiento bajo condiciones ideales de laboratorio, sino aquella que preserva robustez y trazabilidad con requerimientos computacionales compatibles con despliegues progresivos y realistas.

En cuarto lugar, la tesis posee relevancia territorial y social. Incorporar explícitamente la cultura vial latinoamericana como objeto de modelado —y no como residuo a eliminar— supone un cambio de enfoque con implicaciones epistemológicas y prácticas. Epistemológicas, porque cuestiona la universalización acrítica de supuestos conductuales derivados de contextos altamente regulados. Prácticas, porque permite diseñar políticas de control más resilientes ante condiciones donde la congestión, el bloqueo de intersecciones y la degradación desigual del servicio afectan de manera directa a poblaciones con menor margen de adaptación, incluido el transporte público y los usuarios de corredores secundarios. En este sentido, la equidad no se plantea como una extensión normativa superficial, sino como una condición necesaria de legitimidad operativa.

Por último, la tesis es pertinente porque propone un lenguaje de evaluación más adecuado para sistemas urbanos complejos. En lugar de describir el problema en términos de cumplimiento o incumplimiento individual, lo reformula como un problema de gestión de riesgo sistémico en redes congestionadas. Esta decisión conceptual evita lecturas moralistas y sitúa la contribución de la inteligencia artificial en el plano que le corresponde: no imponer disciplina sobre los usuarios, sino estabilizar la operación del sistema cuando la red se enfrenta a condiciones adversas, minimizar la probabilidad de colapso extremo y contener la propagación espacial de los costos de congestión. Bajo esta óptica, la investigación aspira a producir una aportación doctoral rigurosa, transferible y relevante para el diseño de sistemas de control urbano más robustos y más justos.

1.6. Estructura del Documento

La presente memoria doctoral se organiza en siete capítulos y anexos complementarios, siguiendo una progresión lógica desde la fundamentación teórica hasta la validación experimental y la discusión crítica:

- **Capítulo 1: Introducción.** Contextualiza el problema, formula las preguntas de investigación, establece objetivos e hipótesis, y justifica la relevancia científica y práctica del estudio.
- **Capítulo 2: Estado del Arte.** Presenta la revisión sistemática de literatura bajo protocolo PRISMA 2020, caracteriza el corpus empírico, evalúa la calidad metodológica y sintetiza las brechas operativas que fundamentan la propuesta.
- **Capítulo 3: Marco Teórico.** Detalla los fundamentos matemáticos y computacionales del modelo: formulación MDP para TSC, arquitectura de Vine Copulas para dependencia de colas, optimización CVaR en RL, métricas de equidad resiliente y esquemas de transferencia eficiente.
- **Capítulo 4: Metodología.** Describe el diseño experimental, el pipeline de datos, la implementación modular del sistema híbrido, los protocolos de entrenamiento, las métricas de evaluación por dimensión y el plan de validación estadística.
- **Capítulo 5: Resultados y Discusión.** Expone los hallazgos experimentales organizados por preguntas de investigación, e incluye análisis comparativo con baselines, pruebas de robustez y evaluación de eficiencia computacional.
- **Capítulo 6: Discusión.** Interpreta los resultados a la luz del estado del arte, analiza implicaciones teóricas y prácticas, identifica limitaciones persistentes y formula recomendaciones para políticas públicas y despliegue urbano.
- **Capítulo 7: Conclusiones y Trabajo Futuro.** Sintetiza las contribuciones, verifica el cumplimiento de objetivos e hipótesis, plantea líneas de investigación futura y ofrece una reflexión final sobre el rol de la IA ética en ciudades inteligentes.
- **Anexos.** Incluyen cadenas de búsqueda documentadas, la matriz completa de extracción SLR, la configuración de hiperparámetros, diagramas PRISMA editables y enlaces al repositorio de código y datos.

Capítulo 2

Revisión Sistemática de Literatura: resultados de la extracción y síntesis temática

2.1. Delimitación y Propósito de la Revisión

La revisión sistemática de literatura que sustenta esta tesis se desarrolló en dos fases secuenciales, siguiendo la metodología propuesta por Torres-Carrión et al. (2018), la cual adapta el protocolo de Kitchenham (2004, 2009) y mantiene coherencia con el estándar de reporte PRISMA 2020 de Page et al. (2021). A diferencia de una revisión lineal centrada exclusivamente en estudios primarios, la revisión distingue con claridad dos niveles analíticos complementarios: una **Fase 1 de meta-revisión**, orientada a examinar las revisiones sistemáticas, *surveys* y *state-of-the-art reviews* ya publicadas, y una **Fase 2 de SLR primaria**, centrada en artículos empíricos originales sobre control semafórico urbano basado en aprendizaje por refuerzo.

El propósito de esta revisión es doble. En primer lugar, la **Fase 1** busca identificar, clasificar y analizar las revisiones existentes en torno al control semafórico inteligente con RL, prestando especial atención a cinco ejes que estructuran la tesis: explicabilidad, equidad, robustez, transferencia interregional y eficiencia computacional. Esta fase cumple una función de validación de novedad, pues permite determinar qué combinaciones temáticas ya han sido cubiertas por la literatura secundaria y qué vacíos persisten. En segundo lugar, la **Fase 2** construye un corpus de estudios empíricos originales que permite caracterizar el estado del arte experimental, cuantificar la cobertura de las preguntas de investigación RQ1–RQ5 y extraer tendencias metodológicas relevantes para el diseño del *framework* doctoral.

La exposición se organiza conforme a esta lógica bifásica. La [Section 2.2](#) presenta el protocolo de búsqueda y cribado, junto con un resumen cuantitativo consolidado de ambas fases. La [Section 2.3](#) detalla la evaluación de calidad aplicada exclusivamente a los estudios primarios de la Fase 2. La

Section 2.4 caracteriza el corpus empírico final ($n = 190$) en términos de entornos de simulación, familias algorítmicas y reproducibilidad. La Section 2.5 expone los resultados de la meta-revisión, incluyendo la clasificación de las 72 revisiones identificadas en grupos de relevancia. La Section 2.6 sintetiza la evidencia primaria por pregunta de investigación. Finalmente, las Sections 2.7 and 2.8 integran los hallazgos en forma de brechas operativas y una síntesis integradora.

2.2. Diseño del Protocolo de Búsqueda y Cribado

2.2.1. Fuentes de Información y Estrategia de Búsqueda

La búsqueda se realizó en cuatro bases de datos académicas indexadas de alta relevancia para ingeniería, informática y sistemas inteligentes: **Scopus**, **IEEE Xplore**, **Web of Science** y **ACM Digital Library**. Las cadenas de búsqueda combinaron descriptores asociados a tres bloques conceptuales. El primero reunió términos vinculados con control semafórico y gestión de tráfico urbano, como *traffic signal control*, *adaptive traffic control*, *intersection management* y *urban traffic*. El segundo integró conceptos propios del aprendizaje por refuerzo y la inteligencia artificial, entre ellos *reinforcement learning*, *deep reinforcement learning*, *multi-agent reinforcement learning* y *artificial intelligence*. El tercer bloque incorporó términos específicos de las dimensiones analíticas de la tesis, tales como *explainable AI*, *fairness*, *equity*, *robustness*, *risk*, *CVaR*, *transfer learning*, *generalization*, *edge computing*, *lightweight*, *anomaly detection* y *driver behavior*.

Para la **Fase 1 (meta-revisión)** se añadió un filtro explícito de tipo documental, orientado a recuperar *systematic reviews*, *surveys*, *state-of-the-art reviews* y *literature reviews*. En la **Fase 2 (SLR primaria)** se conservaron las mismas familias de términos, pero se eliminó la restricción por tipo de documento, con el fin de capturar estudios empíricos originales susceptibles de evaluación metodológica detallada.

2.2.2. Criterios de Elegibilidad

En la **Fase 2**, los criterios de inclusión exigieron que los documentos fueran artículos de revista o ponencias de conferencia con experimentación empírica o validación por simulación; que estuvieran centrados en control semafórico urbano basado en RL, DRL o aprendizaje multiagente; que reportaran métricas cuantitativas de desempeño —como demora, longitud de cola, *throughput* o tiempo de viaje— junto con al menos una línea base; y que describieran con suficiente detalle el entorno experimental, el algoritmo y las condiciones de evaluación.

Los criterios de exclusión de la Fase 2 eliminaron estudios duplicados entre bases de datos, trabajos fuera del alcance del problema semafórico urbano —por ejemplo, *eco-driving*, tráfico aéreo o conducción autónoma sin componente de control semafórico—, documentos sin evidencia cuantitativa verificable o sin validación, y artículos con evaluación metodológica inferior al umbral de aceptación fijado en $QA < 3.0$.

En la **Fase 1**, los criterios fueron de naturaleza cualitativa. Se incluyeron revisiones que abordan al menos uno de los ejes centrales de la tesis —control semafórico con RL, equidad, robustez, transferencia y eficiencia *edge*— y se excluyeron aquellas centradas en dominios cuya transferencia conceptual al problema semafórico resultaba débil o no justificable, como redes de telecomunicaciones, ciberseguridad, minería de datos genérica o tráfico aéreo y marítimo.

2.2.3. Flujo de Selección

La [Table 2.1](#) resume el flujo de selección consolidado para ambas fases, manteniendo la lógica de identificación, depuración, cribado, elegibilidad e inclusión propia de PRISMA 2020.

Tabla 2.1: Resumen cuantitativo del flujo de selección en las dos fases de la revisión

Fase	Objetivo	Registros iniciales	Tras depuración	Tras cribado/elegibilidad	Incluidos
Fase 1: meta-revisión	Identificar revisiones existentes (<i>surveys</i> , SLR y <i>state-of-the-art</i>)	101	72	72	72
Fase 2: SLR primaria	Estudios empíricos de control semafórico con RL	290	269	230	190

Los **290 registros iniciales** de la Fase 2 proceden de la búsqueda en las cuatro bases de datos. Tras eliminar duplicados y aplicar el cribado por título y resumen, **230 estudios** pasaron a evaluación a texto completo mediante el instrumento de calidad. De ellos, **40** fueron excluidos por no alcanzar el umbral mínimo, lo que dio lugar a un corpus primario final de **190 estudios empíricos**. En paralelo, la Fase 1 permitió consolidar **72 revisiones únicas** como base para la validación del vacío de conocimiento.

2.3. Evaluación de la Calidad Metodológica del Corpus Primario

2.3.1. Instrumento de Evaluación

La calidad metodológica de los 230 estudios primarios que superaron el cribado inicial se evaluó mediante un instrumento de cinco criterios binarios, adaptado de Kitchenham et al. (2009) y Bacca et al. (2014). Cada criterio recibió una puntuación de 0 o 1, de modo que la puntuación total por estudio osciló entre 0 y 5. Los criterios fueron los siguientes:

1. descripción explícita del entorno de simulación, incluyendo simulador, topología y parámetros relevantes;

2. reproducibilidad, entendida como disponibilidad de código abierto o descripción suficientemente detallada para replicación;
3. reporte de métricas cuantitativas de desempeño;
4. comparación con al menos una línea base pertinente;
5. justificación de la selección algorítmica o arquitectónica.

Sobre la base de esta escala se fijó un umbral de inclusión de $QA \geq 3.0$. Esta decisión metodológica permitió preservar el equilibrio entre amplitud del corpus y rigor analítico, evitando que estudios con descripción insuficiente o evidencia limitada distorsionaran la síntesis principal.

2.3.2. Distribución de Puntuaciones

La [Table 2.2](#) muestra la distribución de calidad metodológica del corpus primario finalmente incluido. Los 40 estudios con QA inferior al umbral fueron excluidos de la síntesis cuantitativa principal, aunque su descarte se documentó en la matriz de extracción para mantener trazabilidad del procedimiento.

Tabla 2.2: Distribución de calidad metodológica del corpus primario ($n = 190$)

Puntuación QA	Calificación	Frecuencia	Porcentaje sobre $n = 190$
5/5	Excelente	26	13.7 %
4/5	Bueno	88	46.3 %
3/5	Aceptable	76	40.0 %
Total incluido		190	100.0 %
(Excluidos QA = 2/5 o 1/5)	Limitado/Insuficiente	40	—

En conjunto, el **60.0 %** del corpus incluido presenta calidad buena o excelente. Este resultado aporta una base metodológica suficientemente sólida para sustentar inferencias sobre tendencias experimentales, brechas temáticas y patrones de diseño algorítmico dentro del estado del arte analizado.

2.4. Caracterización del Corpus Empírico ($n = 190$)

2.4.1. Entornos de Simulación y Validación

Los estudios primarios muestran una marcada concentración en plataformas de microtráfico consolidadas. La [Table 2.3](#) resume los simuladores predominantes dentro del corpus final.

Tabla 2.3: Plataformas de simulación predominantes en el corpus primario ($n = 190$)

Simulador	Frecuencia	Porcentaje
SUMO (<i>Simulation of Urban MObility</i>)	136	71.6 %
CityFlow	30	15.8 %
Otros (VISSIM, Aimsun, PARAMICS, etc.)	23	12.1 %
No reportado	1	0.5 %

La clara preponderancia de **SUMO** justifica su selección como plataforma experimental de referencia en la tesis. Al mismo tiempo, la presencia de **CityFlow** como segunda opción confirma un interés creciente por configuraciones de mayor escala, especialmente en escenarios multiagente. No obstante, la evidencia también sugiere una dependencia importante de configuraciones de simulación altamente controladas, lo que limita la representación de contextos operativos más heterogéneos.

2.4.2. Algoritmos de RL y Arquitecturas Dominantes

Desde el punto de vista algorítmico, el corpus presenta un predominio de enfoques *value-based*, especialmente DQN y sus variantes. Sobre los 190 estudios incluidos, se identificaron **101 estudios** con presencia de métodos de esta familia, equivalentes al **53.2 %** del corpus. En segundo lugar aparecen los enfoques basados en gradiente de política, con **43 estudios** que emplean PPO (22.6 %) y **10 estudios** que utilizan SAC (5.3 %). El resto se distribuye entre A2C, DDPG, TD3 y otras combinaciones híbridas o comparativas.

Esta distribución confirma dos patrones relevantes. Por una parte, persiste una tradición consolidada de diseño basada en DQN, favorecida por su simplicidad relativa y su temprana adopción en control semafórico inteligente. Por otra, se observa un desplazamiento progresivo hacia arquitecturas como PPO y SAC cuando el problema exige mayor estabilidad de entrenamiento, manejo de espacios de acción más complejos o coordinación multiagente con restricciones operativas adicionales.

2.4.3. Transparencia y Reproducibilidad

En materia de apertura metodológica, la literatura continúa mostrando limitaciones significativas. Solo **45 de los 190 estudios** incluidos, equivalentes al **23.7 %**, reportan código abierto, repositorios verificables o materiales suficientes para facilitar una replicación independiente. Este resultado refuerza la necesidad de que la presente tesis adopte una estrategia explícita de transparencia documental, trazabilidad experimental y disponibilidad de artefactos reproducibles.

2.5. Resultados de la Meta-Revisión de Revisiones Existentes

2.5.1. Corpus de Revisiones Identificadas

La búsqueda de revisiones sistemáticas, *surveys* y *state-of-the-art reviews* produjo **101 registros iniciales**. Tras eliminar duplicados y aplicar un cribado por título y resumen, se retuvieron **72 revisiones únicas**, publicadas entre 2008 y 2025. Posteriormente, estas revisiones se clasificaron según su alineación con las preguntas de investigación de la tesis: RQ1, explicabilidad; RQ2, transferencia y generalización interregional; RQ3, robustez y riesgo; RQ4, equidad; y RQ5, eficiencia computacional.

Con base en esa alineación se definieron tres grupos de relevancia. El **Grupo A** reúne 16 revisiones de alta relevancia que abordan de forma directa al menos uno de los ejes centrales de la tesis. El **Grupo B** incluye 12 revisiones de relevancia media, útiles como soporte contextual o metodológico. El **Grupo C** agrupa 44 revisiones de baja relevancia, excluidas de la discusión principal por pertenecer a dominios periféricos o poco transferibles al problema de control semafórico urbano.

2.5.2. Revisiones de alta relevancia (Grupo A)

La [Table 2.4](#) presenta las 16 revisiones clasificadas en el Grupo A, junto con su foco principal y su relación con las preguntas de investigación.

Tabla 2.4: Revisiones de alta relevancia (Grupo A, $n = 16$)

Referencia	Autor(es)	Año	Enfoque principal	Relación con RQ
Maheshwari et al. (2025)	Maheshwari et al.	2025	Simulación urbana con ML y caso RL en semáforos	RQ2, RQ5
Vihurskyi (2024)	Vihurskyi	2024	Optimización de tráfico urbano con ML, RL y anomalías	RQ1, RQ3, RQ5
Rong et al. (2025)	Rong et al.	2025	IA generativa en ITS y discusión de explicabilidad	RQ1
Zhang et al. (2024)	Zhang et al.	2024	RL y CAVs para control cooperativo de semáforos	RQ2, RQ4
Gheorghe and Soica (2025)	Gheorghe y Soica	2025	AI/IoT en control adaptativo de tráfico	RQ3, RQ5
Ozioko et al. (2022)	Ozioko et al.	2022	Coordinación de intersecciones con tráfico mixto	RQ2, RQ3
Ali et al. (2025)	Ali et al.	2025	<i>Federated learning</i> para CAVs y transferencia	RQ2, RQ5
Jain and Pandey (2025)	Jain y Pandey	2025	Optimización de tráfico con IA y discusión comparativa	RQ1, RQ3
Si et al. (2025)	Si et al.	2025	<i>Deep learning</i> para TSC con <i>federated/meta-learning</i>	RQ2, RQ5
Saini and Srivastava (2025)	Saini y Srivastava	2025	Optimización en tiempo real con <i>deep learning</i> y edge	RQ5
Thamaraiselvi et al. (2025)	Thamaraiselvi et al.	2025	RL para TSC, IoT y sistemas adaptativos	RQ3, RQ4
Zhao et al. (2024)	Zhao et al.	2024	DRL para TSC y revisión de cinco años	RQ3, RQ4
Han et al. (2023)	Han et al.	2023	Desafíos de implementación de RL en TSC	RQ2, RQ5
Noaen et al. (2022)	Noaen et al.	2022	SLR de RL en redes urbanas	RQ3, RQ4
Liu et al. (2024)	Liu et al.	2024	DRL para navegación en intersecciones con AVs	RQ2
Miao et al. (2021)	Miao et al.	2021	DRL para TSC en contextos <i>single</i> y multiagente	RQ3

Del análisis del Grupo A emergen tres hallazgos centrales. En primer lugar, **la explicabilidad y la equidad ocupan un lugar claramente marginal** dentro de la literatura secundaria. Aunque revisiones recientes como las de Rong et al. (2025) o Jain y Pandey (2025) mencionan la importancia de la transparencia, ninguna operacionaliza la equidad mediante indicadores distributivos explícitos ni desarrolla mecanismos de auditoría en línea compatibles con el control semafórico adaptativo. En segundo lugar, **la robustez suele abordarse como tolerancia a perturbaciones observadas**, pero no como gestión formal del riesgo extremo; en consecuencia, la literatura revisada carece de tratamientos explícitos basados en medidas coherentes de riesgo como CVaR. En tercer lugar, **la transferencia interregional y la eficiencia para despliegue en infraestructura edge** aparecen de forma recurrente como desafíos abiertos, pero sin una propuesta integradora que articule ambos requisitos con criterios de interpretabilidad y justicia operacional.

2.5.3. Revisiones de relevancia media (Grupo B)

La [Table 2.5](#) sintetiza las 12 revisiones clasificadas como de relevancia media. Aunque no justifican por sí mismas el vacío central de la tesis, sí aportan contexto metodológico valioso en predicción de tráfico, *edge analytics*, sensado y dependencias espaciotemporales.

Tabla 2.5: Revisiones de relevancia media (Grupo B, $n = 12$)

Referencia	Autor(es)	Año	Aportación complementaria
Pravin and S (2025)	Pravin y Nancy Noella	2025	Predicción de tráfico con métodos ML/DL
Bakir et al. (2024)	Bakir et al.	2024	Modelos de predicción de congestión
Grigorev et al. (2024)	Grigorev et al.	2024	Duración de incidentes y modelado de anomalías
Badidi et al. (2023)	Badidi et al.	2023	<i>Edge video analytics</i> con hardware limitado
Bisio et al. (2022)	Bisio et al.	2022	Monitoreo con drones y sensado
Cui et al. (2023)	Cui et al.	2023	Correlación espaciotemporal y dependencias
Sirohi et al. (2020)	Sirohi et al.	2020	CNN para ITS y tareas de percepción
Razali et al. (2021)	Razali et al.	2021	Predicción de flujo con ML/DL
Cui et al. (2022)	Cui et al.	2022	Patrones de movilidad vehicular
Noroozi et al. (2023)	Noroozi et al.	2023	Automatización y consumo energético
Vikruthi et al. (2024)	Vikruthi et al.	2024	Priorización de vehículos de emergencia con DL
Jiang et al. (2021)	Jiang et al.	2021	<i>Benchmark</i> de predicción DL-Traff

2.5.4. Síntesis de la Meta-Revisión

La síntesis de la Fase 1 permite afirmar que **ninguna de las 72 revisiones analizadas integra simultáneamente** los cinco componentes que estructuran la propuesta doctoral: *(i)* modelado probabilístico interpretable basado en *Vine Copulas* para generación de escenarios de estrés; *(ii)* optimización sensible al riesgo mediante CVaR; *(iii)* equidad operacional explícita mediante índice de Gini; *(iv)* transferencia interregional con requerimientos computacionales ligeros; y *(v)* viabilidad de despliegue en infraestructura *edge*. Este vacío de conocimiento no solo justifica la continuidad hacia la SLR primaria, sino que también delimita con mayor precisión el espacio de contribución original de la tesis.

2.6. Síntesis de la Evidencia por Pregunta de Investigación ($n = 190$)

La [Table 2.6](#) cuantifica la cobertura de cada pregunta de investigación dentro de los 190 estudios empíricos incluidos. La clasificación se basa en las etiquetas consolidadas en la matriz de extracción temática del corpus.

Tabla 2.6: Cobertura temática del corpus primario según pregunta de investigación ($n = 190$)

Dimensión analítica	Frecuencia	Porcentaje sobre $n = 190$
RQ1: Explicabilidad / XAI	9	4.7 %
RQ2: Transferencia / generalización interregional	18	9.5 %
RQ3: Robustez / manejo de anomalías	110	57.9 %
RQ4: Equidad / <i>fairness</i> distributiva	24	12.6 %
RQ5: Eficiencia computacional / edge computing	25	13.2 %
Código abierto / reproducibilidad	45	23.7 %

Los resultados muestran que **la robustez (RQ3)** es la dimensión más desarrollada, con presencia en el 57.9 % del corpus. Sin embargo, la mayoría de estos trabajos entiende la robustez como tolerancia a perturbaciones observadas —por ejemplo, variaciones de demanda o fallos de sensado— y no como gestión formal del riesgo extremo. Solo un subconjunto muy reducido incorpora medidas compatibles con la lógica de riesgo de cola que la tesis plantea mediante CVaR.

En contraste, **la explicabilidad (RQ1)** presenta una cobertura mínima, de apenas 4.7 %. Los pocos estudios que la abordan, entre ellos contribuciones como las de Schreiber et al. (2022) o Yang et al. (2024), recurren principalmente a mecanismos *post-hoc*, como análisis de importancia o máscaras de atención, sin ofrecer explicaciones en línea ni trazabilidad operativa durante la toma de decisiones del agente. **La equidad (RQ4)** también mantiene una presencia limitada. Aunque algunos trabajos, como Chen et al. (2021) y Fang et al. (2022), introducen señales de justicia distributiva, en la mayoría de los casos esta dimensión se trata como un objetivo secundario o una corrección ex-post, y no como un componente estructural de la recompensa.

Finalmente, **la transferencia interregional (RQ2)** y **la eficiencia computacional para despliegues edge (RQ5)** muestran coberturas inferiores al 15 %, lo que confirma su carácter emergente dentro del estado del arte. La evidencia disponible sugiere, por tanto, un escenario desequilibrado: abundan los estudios orientados a optimizar métricas promedio bajo condiciones controladas, mientras escasean aquellos que articulan simultáneamente interpretabilidad, justicia, adaptación entre contextos y viabilidad computacional realista.

2.7. Brechas del Estado del Arte y Posicionamiento de la Tesis

La integración de los resultados de la Fase 1 y la Fase 2 permite identificar cinco brechas operativas que estructuran el posicionamiento innovador de la tesis.

1. **Ausencia de un modelo generativo interpretable para escenarios de estrés.** La literatura primaria y secundaria recurre mayoritariamente a ruido independiente, GANs opacas o *transformers* de alta complejidad para generar condiciones adversas. Ninguno

de los enfoques revisados utiliza *Vine Copulas* para capturar dependencias no lineales y de cola pesada de forma transparente. Esta brecha se vincula de manera directa con RQ1 y RQ3.

2. **Falta de gestión explícita del riesgo de cola en el control semafórico.** Aunque la robustez es la dimensión más tratada, ningún estudio revisado incorpora CVaR como penalización explícita en la función objetivo del agente de RL. La omisión es especialmente relevante en redes congestionadas, donde los promedios pueden ocultar eventos extremos con consecuencias sistémicas severas. Esta brecha responde a RQ3.
3. **Equidad distributiva tratada como objetivo secundario o *post-hoc*.** Solo un número muy reducido de estudios incorpora señales de justicia en la recompensa, y ninguno emplea el índice de Gini como penalización explícita sobre desigualdades en tiempos de espera entre movimientos o accesos. Tampoco se evalúa de forma sistemática la degradación de la equidad bajo condiciones de estrés. Esta brecha se relaciona con RQ4.
4. **Transferencia interregional con requisitos computacionales poco realistas.** Los enfoques existentes —como *fine-tuning*, meta-RL o *federated learning*— suelen depender de arquitecturas pesadas y de grandes volúmenes de datos. La literatura revisada no explora soluciones ligeras basadas en recalibración de estructuras probabilísticas que permitan adaptación rápida a nuevas regiones con pocos datos locales. Esta brecha conecta con RQ2 y RQ5.
5. **Validación dominada por entornos idealizados.** El predominio de SUMO con configuraciones por defecto presupone, en muchos casos, obediencia vehicular casi perfecta, sensorica abundante y topologías regulares. La literatura rara vez incorpora comportamientos anómalos estructurados —como invasión de intersección, bloqueo de caja o tiempos de reacción atípicos— que resultan especialmente pertinentes para contextos urbanos latinoamericanos. Esta brecha atraviesa de manera transversal las cinco preguntas de investigación.

En respuesta a estas brechas, la tesis propone un *framework* integrado que combina *Vine Copulas* para generación interpretable de escenarios de estrés, optimización CVaR para gestión del riesgo de cola, índice de Gini en la función de recompensa para promover equidad resiliente, un agente RL ligero basado en PPO/SAC con estados agregados y ejecución en CPU, y un módulo de transferencia sustentado en recalibración probabilística con baja dependencia de datos locales. De este modo, la contribución doctoral se posiciona no como una mera mejora incremental sobre el rendimiento promedio, sino como una reformulación del problema bajo criterios simultáneos de robustez, equidad, interpretabilidad y viabilidad operativa.

2.8. Síntesis del Capítulo

Los resultados de la revisión sistemática desarrollada en dos fases permiten establecer cinco conclusiones principales. **Primero**, la meta-revisión de 72 revisiones existentes confirma un vacío de conocimiento claro: ninguna propuesta previa integra en un mismo marco modelado probabilístico interpretable, optimización del riesgo de cola, equidad explícita, transferencia ligera y eficiencia para despliegue *edge*. **Segundo**, la SLR primaria de 190 estudios empíricos cuantifica la baja cobertura de las dimensiones más cercanas a la contribución doctoral, especialmente explicabilidad, transferencia, equidad y eficiencia computacional, mientras que la robustez aparece con frecuencia pero sin una formulación formal del riesgo extremo. **Tercero**, SUMO emerge como el simulador dominante, lo que justifica su uso en la fase experimental de la tesis, aunque la literatura revisada rara vez lo calibra para representar comportamientos anómalos o contextos de infraestructura limitada. **Cuarto**, la transparencia y reproducibilidad continúan siendo insuficientes, dado que menos de una cuarta parte del corpus libera código o materiales verificables. **Quinto**, las brechas identificadas fundamentan directamente el diseño del *framework* híbrido desarrollado en los capítulos siguientes.

En consecuencia, la evidencia extraída y sintetizada en este capítulo no solo confirma la vigencia y pertinencia del problema de investigación, sino que también justifica de manera directa la arquitectura conceptual y metodológica que se desarrolla en los capítulos dedicados al marco teórico y a la metodología experimental.

Capítulo 3

Marco Teórico

3.1. Fundamentos del Sistema o Modelo Propuesto

La gestión semafórica urbana es un problema de decisión secuencial bajo incertidumbre en el que el estado del sistema cambia de forma continua por la interacción entre demanda vehicular, estructura de red, eventos exógenos y restricciones operativas. En la literatura científica reciente, el aprendizaje por refuerzo profundo ha demostrado ventajas frente a controladores estáticos o puramente heurísticos al aprender políticas adaptativas directamente desde la interacción con simuladores de tráfico. Sin embargo, el mismo estado del arte muestra cuatro limitaciones persistentes: escasa explicabilidad, débil tratamiento de la equidad, sensibilidad a observaciones incompletas o ruidosas y dificultades de escalabilidad hacia redes urbanas amplias (Schreiber et al., 2022; Chen et al., 2021; Guo et al., 2023; Wang et al., 2021).

Con base en las fuentes científicas seleccionadas del SLR, este marco teórico adopta una visión integrada del control semafórico inteligente. Primero, la política debe ser *explicable*, de modo que las variables de tráfico que motivan cada decisión puedan auditarse y relacionarse con el comportamiento del agente, tal como muestran Schreiber et al. mediante aproximadores de función interpretables y explicaciones poshoc con SHAP (Schreiber et al., 2022). Segundo, la política debe ser *equitativa*, es decir, no limitarse a minimizar la demora agregada sino considerar la distribución de los beneficios entre corrientes mayoritarias y minoritarias, siguiendo la línea de Chen et al. y Fang et al., quienes introducen señales de recompensa sensibles a justicia distributiva y duración de fase (Chen et al., 2021; Fang et al., 2022). Tercero, el sistema debe ser *robusto* frente a observabilidad parcial, ruido y eventos inesperados, como plantea el enfoque ontológico de Guo et al. para despliegues en el borde (Guo et al., 2023). Cuarto, el método debe preservar *escalabilidad y cooperación* en redes extensas, atributo desarrollado por Wang et al. mediante aprendizaje multiagente con aproximación de campo medio (Wang et al., 2021).

Desde esta perspectiva, el modelo propuesto en la tesis se sustenta en cinco principios teóricos: (i) representación estructurada del estado, (ii) optimización secuencial mediante aprendizaje por refuerzo, (iii) modelado explícito de riesgo y eventos extremos, (iv) incorporación de criterios de

equidad en la función objetivo y (v) compatibilidad con infraestructura *edge* y con escenarios urbanos parcialmente observables. Estos principios no se plantean como componentes independientes, sino como restricciones conjuntas que deben cumplirse en toda formulación rigurosa del control semafórico inteligente.

3.2. Modelado Matemático del Problema

Se modela la red vial como un grafo dirigido $G = (V, E)$, donde cada nodo $v \in V$ representa una intersección controlada y cada arista $e \in E$ representa un tramo vial o carril con capacidad finita. La dinámica del sistema depende del patrón de llegadas, del enrutamiento entre enlaces, de la fase activa en cada intersección y de perturbaciones exógenas. En este contexto, el objetivo general consiste en aprender una política π que asigne acciones de control semafórico para minimizar congestión, demoras y riesgo operacional sin sacrificar equidad entre usuarios.

Sea $i \in V$ una intersección. Para cada intervalo de decisión t , se observan magnitudes locales como longitud de cola, tiempo de espera, presión entre carriles de entrada y salida, fase actual y tiempo transcurrido desde el último cambio. La formulación del problema requiere equilibrar dos necesidades contrapuestas: por un lado, un estado suficientemente rico para capturar la dinámica del flujo; por otro, una representación compacta que permita entrenamiento estable e inferencia eficiente. La evidencia reportada por Fang et al., Guo et al. y Wang et al. sugiere que las representaciones estructuradas basadas en presión, duración de fase, vecindad y variables agregadas son más apropiadas que representaciones visuales de alta dimensión para contextos operativos realistas (Fang et al., 2022; Guo et al., 2023; Wang et al., 2021).

3.2.1. Formulación MDP para Control Semafórico Urbano

El problema se formula como un Proceso de Decisión de Markov (MDP) definido por la tupla:

$$\mathcal{M} = \langle \mathcal{S}, \mathcal{A}, \mathcal{P}, \mathcal{R}, \gamma \rangle,$$

donde $\mathcal{S}$ es el espacio de estados, $\mathcal{A}$ el espacio de acciones, $\mathcal{P}(s_{t+1} \mid s_t, a_t)$ la dinámica de transición, $\mathcal{R}$ la recompensa inmediata y $\gamma \in (0, 1)$ el factor de descuento.

Para una intersección i , se propone un estado local de la forma:

$$s_{i,t} = [\mathbf{q}_{i,t}, \mathbf{w}_{i,t}, \mathbf{p}_{i,t}, \phi_{i,t}, \tau_{i,t}, \mathbf{z}_{i,t}],$$

donde $\mathbf{q}_{i,t}$ representa longitudes de cola por carril, $\mathbf{w}_{i,t}$ tiempos de espera acumulados, $\mathbf{p}_{i,t}$ presión de tráfico, $\phi_{i,t}$ la fase activa, $\tau_{i,t}$ la edad de la fase y $\mathbf{z}_{i,t}$ variables contextuales o latentes asociadas con ruido, incidencias o prioridad operacional. La inclusión de presión y duración de fase sigue la evidencia de *MonitorLight*, donde ambas variables mejoran la sensibilidad del controlador ante condiciones estacionarias y transitorias (Fang et al., 2022). La incorporación de

variables latentes o semánticas se justifica por el enfoque de observación aumentada de Guo et al., orientado a resolver información incompleta y eventos inesperados (Guo et al., 2023).

El espacio de acciones puede formularse de dos maneras. En una versión discreta, el agente selecciona la siguiente fase admisible. En una versión continua o semidiscreta, además determina la duración del verde o la partición temporal entre movimientos compatibles. La segunda alternativa es teóricamente más expresiva cuando se desea evitar cambios innecesarios y adaptar la señalización a patrones asimétricos de demanda. Por ello, el marco propuesto favorece una acción del tipo $a_{i,t} = (\phi_{i,t+1}, g_{i,t+1})$, donde $g_{i,t+1}$ denota el tiempo verde o *green split* sujeto a restricciones de seguridad operacional:

$$g_{\min} \leq g_{i,t+1} \leq g_{\max}.$$

La transición del sistema no es conocida en forma analítica cerrada, pues depende de interacciones no lineales entre demanda, propagación de colas, comportamiento de los conductores y decisiones simultáneas de múltiples intersecciones. Por ello, el simulador o entorno digital actúa como aproximación de $\mathcal{P}$. Esta aproximación es consistente con la práctica experimental observada en los estudios del SLR, que emplean SUMO, CityFlow u otros entornos de simulación como soporte del aprendizaje (Schreiber et al., 2022; Chen et al., 2021; Guo et al., 2023; Fang et al., 2022; Wang et al., 2021).

3.3. Modelos de Aprendizaje o Predicción

La selección del modelo de aprendizaje no puede reducirse a la obtención del menor tiempo promedio de viaje. En el contexto urbano, un controlador útil debe ofrecer capacidad de generalización, estabilidad de entrenamiento y cierta trazabilidad sobre las razones de sus decisiones. Schreiber et al. muestran que la elección del aproximador de función afecta simultáneamente el rendimiento y la explicabilidad del agente, lo que obliga a considerar la arquitectura no solo por precisión sino también por auditabilidad (Schreiber et al., 2022).

En este marco, el aprendizaje se concibe como un proceso de aproximación funcional sobre políticas y/o funciones de valor. Cuando el espacio de acciones es discreto, las familias tipo DQN resultan naturales; cuando la acción incluye tiempos continuos de verde, son más apropiados métodos actor–crítico o gradiente de política. En ambos casos, el aprendizaje debe apoyarse sobre estados agregados y compactos para reducir la varianza de estimación y facilitar el despliegue computacional.

3.3.1. Arquitectura Principal: Vine Copulas para Generación de Escenarios

El capítulo adopta una arquitectura teórica en la que el aprendizaje por refuerzo se complementa con un módulo probabilístico de generación de escenarios. La motivación es que las variables de

tráfico urbano presentan dependencias no lineales, colas pesadas y variaciones conjuntas que rara vez pueden representarse correctamente mediante supuestos gaussianos. En consecuencia, una familia de *vine copulas* resulta adecuada para modelar dependencias entre flujos de entrada, tiempos de llegada, eventos incidentales y perturbaciones contextuales, conservando flexibilidad estructural.

Formalmente, si $\mathbf{X} = (X_1, \dots, X_d)$ es el vector de variables aleatorias que describe condiciones de tráfico y contexto, su distribución conjunta puede descomponerse como:

$$F_{\mathbf{X}}(x_1, \dots, x_d) = C(F_1(x_1), \dots, F_d(x_d)),$$

donde F_j son distribuciones marginales y C es una cópula que captura la dependencia. El uso de *regular vines* permite factorizar C en cópulas bivariadas condicionales, generando escenarios sintéticos plausibles para entrenar y someter a estrés la política de control. Aunque las fuentes del SLR empleadas en este capítulo no desarrollan cópulas explícitamente, sí justifican la necesidad de modelar incertidumbre estructurada, ruido y eventos inesperados en tráfico urbano (Guo et al., 2023; Fang et al., 2022). Por tanto, el módulo de cópulas se integra como extensión probabilística coherente con la evidencia revisada.

3.4. Aprendizaje por Refuerzo, Optimización o Control

La teoría del aprendizaje por refuerzo proporciona el marco para encontrar políticas que maximicen un retorno esperado acumulado. Sin embargo, en aplicaciones urbanas críticas, optimizar solamente la esperanza del retorno puede inducir políticas frágiles ante escenarios extremos. Una reducción del promedio de demora puede coexistir con episodios severos de congestión localizada, inanición de accesos secundarios o colapso temporal de una zona de la red. Esta observación motiva una formulación explícitamente sensible al riesgo.

3.4.1. Formulación del Problema Risk-Aware

Sea R_t la recompensa instantánea y $G_t = \sum_{k=0}^{\infty} \gamma^k R_{t+k}$ el retorno descontado. En la formulación clásica, se busca:

$$\max_{\pi} \mathbb{E}_{\pi}[G_t].$$

En este trabajo, el criterio se amplía para incorporar aversión al riesgo sobre pérdidas operacionales extremas. Si L_t representa una variable de pérdida asociada con demoras severas, sobrepresión o desequilibrio extremo, puede emplearse la medida *Conditional Value at Risk* (CVaR):

$$\text{CVaR}_{\alpha}(L) = \mathbb{E}[L \mid L \geq \text{VaR}_{\alpha}(L)], \quad \alpha \in (0, 1).$$

Así, el objetivo se expresa como una optimización multiobjetivo regularizada:

$$\max_{\pi} \mathbb{E}_{\pi}[G_t] - \lambda_r \text{CVaR}_{\alpha}(L_t),$$

donde $\lambda_r > 0$ pondera la penalización por riesgo. Esta formulación protege al sistema contra episodios de cola y favorece políticas más conservadoras frente a eventos de alta severidad, un requisito alineado con los hallazgos de robustez y respuesta rápida reportados para escenarios inesperados (Guo et al., 2023; Wang et al., 2021).

3.4.2. Algoritmo Principal: PPO/SAC con Penalización CVaR

El marco teórico admite dos familias algorítmicas principales. Si la acción incorpora decisiones continuas de duración de verde, *Soft Actor-Critic* (SAC) ofrece una base adecuada por su eficiencia muestral y su tratamiento entropizado de la exploración. Si la política se representa con restricciones de actualización más conservadoras, *Proximal Policy Optimization* (PPO) constituye una alternativa robusta. En ambos casos, la función objetivo del agente se modifica mediante un término de penalización por riesgo y, cuando corresponda, por inequidad distributiva.

Desde el punto de vista conceptual, esta elección prolonga dos hallazgos del SLR: la utilidad de representaciones compactas e interpretables para la estimación de valor (Schreiber et al., 2022) y la conveniencia de diseñar mecanismos de estabilidad y cooperación cuando el sistema escala a múltiples intersecciones (Wang et al., 2021). En una extensión multiagente, la política global puede factorizarse en agentes locales con intercambio limitado de estado vecino, preservando escalabilidad sin perder coordinación táctica.

3.5. Modelado de Dependencias o Incertidumbre

La incertidumbre relevante en control semafórico no se restringe a la variabilidad de llegadas. También incluye fallos parciales de sensado, ruido de medición, eventos incidentales y perturbaciones espacio-temporales que alteran simultáneamente varias corrientes. Ignorar estas dependencias lleva a políticas sobreajustadas a condiciones promedio y con bajo desempeño en explotación.

3.5.1. Estructura del Modelo Probabilístico o Estadístico

El modelo probabilístico propuesto combina dos niveles. En el nivel marginal, cada variable de tráfico se ajusta mediante distribuciones empíricas o paramétricas flexibles para capturar asimetría y colas pesadas. En el nivel conjunto, una estructura de cópulas tipo vine modela dependencias entre intersecciones, accesos y perturbaciones contextuales. Esta representación permite muestrear escenarios con dependencias realistas y evaluar la política sobre configuraciones ordinarias y adversas.

En términos operativos, el vector de incertidumbre ξ_t puede incluir demanda por movimiento, ruido de sensor, tasa de vehículos prioritarios y probabilidad de incidente. Entonces, la transición se reescribe como:

$$s_{t+1} \sim \mathcal{P}(\cdot \mid s_t, a_t, \xi_t).$$

La consideración explícita de ξ_t es consistente con el enfoque de Guo et al., donde la observabilidad parcial y los eventos inesperados dejan de ser ruido residual y pasan a constituir parte del problema de decisión (Guo et al., 2023).

3.6. Equidad, Robustez o Criterios Éticos

La equidad constituye un criterio sustantivo y no accesorio dentro del control semafórico urbano. Una política que minimiza la demora total pero sacrifica sistemáticamente un subconjunto de usuarios puede ser eficiente en promedio y, al mismo tiempo, socialmente inaceptable. La literatura científica revisada demuestra que la inclusión de señales de justicia distributiva modifica de manera significativa la conducta del agente y evita estrategias utilitaristas extremas (Chen et al., 2021; Fang et al., 2022).

3.6.1. Métricas de Evaluación Ética o de Robustez

La evaluación del sistema se organiza en tres grupos de métricas. El primer grupo mide eficiencia global: tiempo medio de viaje, demora promedio, longitud de cola, velocidad media y throughput, métricas ampliamente utilizadas en los estudios del SLR (Schreiber et al., 2022; Chen et al., 2021; Guo et al., 2023; Wang et al., 2021). El segundo grupo mide equidad distributiva mediante índices como Jain o coeficientes de desigualdad aplicados a tiempos de espera y servicio por movimiento (Chen et al., 2021). El tercer grupo mide robustez con estadísticas de dispersión y cola, por ejemplo máximo tiempo de espera, desviación estándar de demoras, percentiles altos y pérdidas extremas asociadas con CVaR_α , de manera coherente con escenarios ruidosos, parciales o inesperados (Guo et al., 2023; Wang et al., 2021).

3.6.2. Función de Recompensa Ajustada (Gini + CVaR)

La recompensa instantánea se diseña como una combinación de eficiencia, equidad y riesgo. Una formulación general es:

$$R_t = -\lambda_1 \text{Delay}_t - \lambda_2 \text{Pressure}_t - \lambda_3 \text{Gini}_t - \lambda_4 \text{CVaR}_\alpha(L_t),$$

donde $\lambda_j > 0$ son coeficientes de ponderación. El término Gini_t penaliza distribuciones desiguales del tiempo de espera entre corrientes o grupos de usuarios, mientras que el término de CVaR penaliza pérdidas extremas. Esta estructura generaliza la lógica de equidad propuesta por Chen

et al. y Fang et al., pero la amplía con un componente explícito de riesgo operacional ([Chen et al., 2021](#); [Fang et al., 2022](#)).

Desde una perspectiva normativa, esta función evita que el agente aprenda políticas que beneficien desproporcionadamente las arterias principales a costa de accesos secundarios, peatones o vehículos con menor volumen. Al mismo tiempo, el término de riesgo desalienta decisiones agresivas que pueden reducir el promedio de demora a cambio de aumentar la probabilidad de bloqueo severo.

3.7. Modelos de Comportamiento o Escenario

La validez de una política de control depende de su capacidad para responder a comportamientos no nominales. Por ello, el entrenamiento y la validación deben considerar perfiles de operación adversos y no solo condiciones promedio.

3.7.1. Perfil 1: Conducción Anómala y Desobediencia Vial

Este perfil incorpora aceleraciones atípicas, tiempos de reacción heterogéneos, invasión de intersección, incumplimiento parcial de fase y detección imperfecta. Teóricamente, su inclusión permite evaluar si la política conserva estabilidad cuando la relación entre observación y estado real se degrada. El sustento para este perfil se encuentra en la evidencia de Guo et al. sobre observaciones ruidosas y parciales, y en la necesidad de estados ricos que no dependan de una única fuente sensorial ([Guo et al., 2023](#)).

3.7.2. Perfil 2: Eventos Exógenos y Fallos de Infraestructura

Este segundo perfil contempla accidentes, aumentos súbitos de demanda, indisponibilidad de sensores, prioridad a vehículos de emergencia y perturbaciones de red. La motivación teórica es evaluar la resiliencia de la política frente a cambios estructurales breves pero severos. Los escenarios inesperados analizados por Guo et al. y la preocupación por estabilidad y robustez en aprendizaje multiagente reportada por Wang et al. fundamentan la incorporación explícita de este tipo de perturbaciones ([Guo et al., 2023](#); [Wang et al., 2021](#)).

3.8. Modelo Híbrido de Optimización o Integración

El modelo resultante es híbrido porque integra una capa de percepción estructurada, una capa probabilística de generación de escenarios y una capa de decisión basada en aprendizaje por refuerzo sensible a equidad y riesgo. La percepción estructurada resume el estado local y vecinal; el

módulo probabilístico produce escenarios dependientes y adversos; el agente actor–critic aprende una política que optimiza eficiencia sin ignorar pérdidas extremas ni desigualdad distributiva.

En su versión distribuida, cada intersección actúa como agente local con acceso a un estado ampliado por variables de vecindad y señales latentes. La coordinación puede lograrse mediante intercambio restringido de resúmenes de estado o mediante mecanismos de cooperación inspirados en aproximaciones de campo medio, siguiendo la lógica de escalabilidad presentada por Wang et al. (Wang et al., 2021). Esta integración permite trasladar el aprendizaje desde la optimización aislada de un cruce hacia la gestión coherente de corredores y subredes urbanas.

3.9. Algoritmo de Entrenamiento Unificado

El entrenamiento unificado se organiza en seis etapas. Primero, se estiman marginales y dependencias del entorno de tráfico a partir de datos históricos y contextuales. Segundo, se generan escenarios ordinarios y adversos mediante el modelo probabilístico. Tercero, se construye el estado estructurado incorporando colas, esperas, presión, duración de fase y variables latentes. Cuarto, se entrena la política con PPO o SAC utilizando la recompensa ajustada por equidad y riesgo. Quinto, se valida el controlador bajo perfiles de ruido, parcial observación y eventos exógenos. Sexto, se examina la interpretabilidad de la política a través del peso efectivo de sus variables de estado, en coherencia con la línea de explicabilidad reportada por Schreiber et al. (Schreiber et al., 2022).

Este flujo unificado no pretende reemplazar las contribuciones previas del estado del arte, sino articularlas en una sola formulación teórica: explicabilidad para auditoría, equidad para legitimidad operativa, robustez para despliegue real y escalabilidad para redes urbanas complejas (Schreiber et al., 2022; Chen et al., 2021; Guo et al., 2023; Fang et al., 2022; Wang et al., 2021).

3.10. Conclusión del Marco Teórico

El marco teórico desarrollado establece que el control semafórico inteligente debe entenderse como un problema de optimización secuencial multiobjetivo bajo incertidumbre estructurada. Las fuentes científicas del SLR muestran que la mejora en métricas agregadas de tráfico, aunque necesaria, es insuficiente cuando no va acompañada de explicabilidad, equidad, robustez y viabilidad computacional (Schreiber et al., 2022; Chen et al., 2021; Guo et al., 2023; Fang et al., 2022; Wang et al., 2021). A partir de esa evidencia, el capítulo propone una formulación MDP ampliada con representación estructurada del estado, modelado probabilístico de dependencias, control sensible al riesgo y una recompensa que internaliza desigualdad distributiva.

En consecuencia, el capítulo no solo fundamenta la metodología del trabajo, sino que delimita el tipo de sistema que se aspira a construir: un controlador semafórico científicamente sustentado, auditable, robusto ante perturbaciones y alineado con criterios de justicia operacional. Sobre

esta base se desarrollará en el capítulo siguiente la estrategia metodológica de implementación, entrenamiento y validación experimental.

Capítulo 4

Metodología

4.1. Diseño General del Sistema

La presente investigación adopta un diseño metodológico cuantitativo, experimental y computacional orientado a evaluar un controlador semafórico inteligente bajo condiciones de operación no ideales. En coherencia con los objetivos planteados en el capítulo introductorio y con la formulación teórica desarrollada en el capítulo precedente, el problema se modela como un Proceso de Decisión de Markov parcialmente observable, donde el agente no accede al estado completo de la red, sino a una representación agregada y operativamente viable de la intersección bajo control. Esta decisión metodológica responde a dos restricciones centrales: por un lado, la disponibilidad incompleta y ruidosa de información en entornos urbanos reales; por otro, la necesidad de construir un sistema desplegable sobre infraestructura computacional moderada, sin depender de sensores perfectos ni de arquitecturas de percepción de alta dimensionalidad (Schreiber et al., 2022; Guo et al., 2023; Fang et al., 2022).

La arquitectura del *framework* se concibe como un sistema híbrido de tres capas estrechamente acopladas. La primera capa corresponde al entorno de simulación microscópica, responsable de reproducir la evolución temporal del tráfico, las interacciones entre vehículos y las restricciones físicas de la red. Esta capa no opera como un entorno determinista cerrado, sino como un medio experimental donde se inyecta variabilidad estocástica mediante archivos de demanda heterogéneos, perfiles de conducción adversa y perturbaciones exógenas. La segunda capa está constituida por un módulo probabilístico basado en *Vine Copulas*, cuyo propósito es representar dependencias no lineales entre variables operativas y generar escenarios de estrés coherentes con una estructura conjunta más realista que la obtenida a partir de ruido independiente o supuestos gaussianos. La tercera capa corresponde a la política de decisión basada en Aprendizaje por Refuerzo Profundo, implementada mediante un esquema actor-critic y optimizada con una función de recompensa multiobjetivo que internaliza simultáneamente eficiencia, riesgo sistémico y equidad distributiva (Chen et al., 2021; Guo et al., 2023; Wang et al., 2021).

En términos funcionales, el flujo metodológico puede describirse así. Primero, el simulador produ-

ce la dinámica base del tráfico sobre una red realista. Segundo, el módulo probabilístico perturba esa dinámica generando perfiles de estrés con dependencias explícitas entre demanda, tiempos de reacción, pérdidas sensoriales e incidentes. Tercero, a partir de la telemetría disponible se construye un estado compacto s_t que resume colas, esperas, presión y fase activa. Cuarto, el agente PPO procesa dicha representación y selecciona una acción discreta admisible. Quinto, la acción se aplica sobre el controlador semafórico mediante la interfaz TraCI, modificando la evolución subsecuente del sistema. Sexto, la recompensa resultante penaliza demora agregada, desigualdad y pérdidas extremas, retroalimentando el aprendizaje de la política. Este ciclo se repite sobre un conjunto amplio de escenarios hasta obtener un controlador estable frente a condiciones nominales y adversas.

El diseño general se aleja deliberadamente de los enfoques que entienden el problema como mera minimización de demora promedio. La metodología asume que una política útil para contextos urbanos reales debe satisfacer cuatro propiedades simultáneas: *(i)* eficiencia operativa, *(ii)* robustez frente a eventos severos, *(iii)* equidad en la distribución del servicio y *(iv)* viabilidad computacional para despliegue progresivo. En consecuencia, el rendimiento del sistema no se juzga solo por promedios globales de viaje, sino también por su capacidad para evitar colas extremas, contener *spillback*, reducir sesgos distributivos y mantener tiempos de inferencia compatibles con esquemas de control en tiempo casi real (Chen et al., 2021; Fang et al., 2022; Guo et al., 2023).

4.2. Pipeline de Datos

4.2.1. Fuentes de Datos y Entorno Experimental

Con el fin de maximizar la validez externa del estudio, los experimentos no se desarrollan sobre cuadrículas sintéticas elementales ni sobre intersecciones abstractas de cuatro accesos perfectamente balanceados. En su lugar, se emplea la red arterial de Hangzhou, China, ampliamente utilizada en investigación de control semafórico por su complejidad topológica y por la disponibilidad de escenarios de demanda consistentes para comparación experimental. La red seleccionada corresponde a una configuración de 4×4 intersecciones, con conectividad suficiente para reproducir interdependencias espaciales entre nodos, propagación de colas y efectos de descoordinación local.

Dentro de esta topología, el entrenamiento y la evaluación se centran en el nodo `intersection_2_2`, ubicado en la zona central del grafo vial. Esta selección responde a criterios metodológicos específicos. Al situarse en una posición interior de la red, la intersección queda expuesta tanto a perturbaciones aguas arriba como a restricciones de descarga aguas abajo, lo que permite observar con mayor claridad fenómenos de bloqueo de caja, transferencia de congestión y pérdida de estabilidad local. Además, el nodo presenta 12 carriles de entrada controlados y ocho fases semafóricas admisibles, constituyendo un nivel de complejidad suficiente para evaluar la política

bajo alta dimensionalidad operativa, pero sin introducir una escala que dificulte la trazabilidad del aprendizaje o la interpretación de resultados.

Para evitar el sobreajuste a un único patrón de llegadas, el *pipeline* utiliza un conjunto de 100 archivos de enrutamiento estocástico en formato XML, cada uno con configuraciones distintas de demanda, proporciones de giro y distribución temporal de flujos. En cada episodio de entrenamiento, el método `reset()` del entorno selecciona aleatoriamente uno de estos escenarios, exponiendo al agente a combinaciones diversas de densidad vehicular, asimetría direccional y presión sobre movimientos competidores. Esta estrategia incrementa la variabilidad de la experiencia de aprendizaje y reduce la probabilidad de que la política memorice un patrón específico de tráfico en lugar de aprender regularidades transferibles.

El uso de múltiples escenarios responde también a una consideración estadística. Cuando el agente se entrena siempre sobre una única serie de llegadas, la política puede adaptarse con precisión al régimen dominante de ese escenario, pero mostrar fragilidad al enfrentar ligeras desviaciones de intensidad, composición modal o correlación entre accesos. La rotación aleatoria entre archivos de demanda introduce una forma de *domain randomization* operativa, apropiada para control semafórico, y crea una base empírica más adecuada para evaluar robustez y generalización en condiciones no estacionarias (Wang et al., 2021; Guo et al., 2023).

4.2.2. Preprocesamiento y Validación PRISMA (Representación del Estado)

El tratamiento de la información sigue un proceso de normalización y estructuración orientado a satisfacer simultáneamente consistencia matemática, estabilidad numérica e interpretabilidad operacional. A partir de la telemetría cruda proporcionada por SUMO y TraCI, se implementa una función de extracción que proyecta el estado dinámico del sistema hacia un espacio vectorial continuo fijo $s_t \in \mathbb{R}^{34}$. La dimensión de observación se mantiene constante a lo largo de todo el entrenamiento y de la evaluación, independientemente de las fluctuaciones particulares del episodio, lo que garantiza compatibilidad con la arquitectura neuronal del agente y evita problemas derivados de entradas de tamaño variable.

La construcción del vector de estado se apoya en variables recurrentemente validadas por la revisión sistemática de literatura y por los trabajos más robustos del campo. En particular, la representación integra cuatro grupos de magnitudes. El primer grupo corresponde a **densidad y colas**, capturadas mediante la longitud de cola acumulada en los 12 carriles de aproximación. Estas variables proporcionan una medida directa del nivel de saturación local y permiten anticipar riesgo de desborde. El segundo grupo representa **tiempos de espera**, definidos como tiempos de detención agregados por acceso y actualizados en tiempo real; estas magnitudes aproximan el costo temporal soportado por los usuarios y constituyen la base de la dimensión de equidad. El tercer grupo incorpora **presión de tráfico**, calculada como diferencia funcional entre la ocupación o demanda en entradas y la capacidad de descarga asociada a salidas, siguiendo la evidencia que muestra la utilidad de esta señal para capturar desequilibrios operativos entre movimientos (Fang et al., 2022). El cuarto grupo codifica el **estado semafórico**, mediante una

representación *one-hot* de la fase activa y la edad de la fase $\tau_{i,t}$, lo que aporta contexto temporal imprescindible para decisiones de cambio seguras y evita oscilaciones excesivas de la política.

Formalmente, la observación puede expresarse como:

$$s_t = [\mathbf{q}_t, \mathbf{w}_t, \mathbf{p}_t, \phi_t, \tau_t],$$

donde $\mathbf{q}_t$ representa el vector de colas, $\mathbf{w}_t$ el vector de esperas agregadas, $\mathbf{p}_t$ la señal de presión, ϕ_t la codificación discreta de la fase activa y τ_t la duración acumulada de la fase en segundos. Antes de alimentar esta observación al agente, las variables continuas se escalan mediante transformaciones lineales acotadas o normalización basada en máximos operativos del entorno. Este paso reduce disparidades entre magnitudes, mejora el condicionamiento del problema de optimización y limita la sensibilidad del modelo a valores extremos espurios.

Aunque el subtítulo menciona PRISMA, en este capítulo el término se utiliza como referente metodológico de validación conceptual de las variables seleccionadas, no como procedimiento de tamizaje documental propiamente dicho. Es decir, la representación del estado no surge de una elección ad hoc, sino de una triangulación entre evidencia del SLR, viabilidad computacional y relevancia operacional. En ese sentido, la selección de 34 características persigue una representación compacta del MDP parcialmente observable, capaz de capturar los elementos suficientes para el control sin incurrir en la maldición de la dimensionalidad ni requerir sistemas sensoriales poco transferibles (Schreiber et al., 2022; Guo et al., 2023; Fang et al., 2022).

4.3. Implementación del Modelo Híbrido

4.3.1. Entrenamiento del Módulo de Copulas

El primer componente de la implementación corresponde a la formalización probabilística de la incertidumbre operacional. En lugar de modelar perturbaciones como ruido blanco independiente o como simples variaciones marginales en la demanda, la metodología utiliza *regular vines* para factorizar la distribución conjunta del sistema en una colección de cópulas bivariadas condicionales. Esta elección permite capturar dependencias asimétricas, no lineales y de cola pesada entre variables como intensidad de arribos, tiempos entre llegadas, fricción conductual, fallos sensoriales y eventos contextuales.

El proceso de entrenamiento del módulo probabilístico se desarrolla en cuatro etapas. Primero, se identifican las variables operativas relevantes para la construcción de escenarios adversos. Segundo, se ajustan distribuciones marginales apropiadas para cada variable, preservando sus dominios y patrones empíricos. Tercero, se estima la estructura de la *vine*, seleccionando secuencialmente las dependencias más informativas y las familias de cópulas más adecuadas según criterios de ajuste. Cuarto, una vez calibrado el modelo, se procede a muestrear realizaciones sintéticas que luego son inyectadas al simulador para construir episodios de entrenamiento y validación bajo

estrés.

La ventaja central de este módulo no radica únicamente en generar variabilidad adicional, sino en hacerlo de forma interpretable. A diferencia de enfoques generativos opacos, la estructura *vine* hace explícitas las relaciones de dependencia entre pares de variables y permite auditar qué combinaciones explican mejor la aparición de escenarios severos. Desde la perspectiva metodológica de la tesis, esta trazabilidad es fundamental porque la robustez del agente no depende solo de cuántos escenarios observa, sino también de la plausibilidad estadística de esos escenarios y de la capacidad del investigador para justificar su construcción.

En la práctica, el módulo de copulas alimenta dos tipos de condiciones experimentales. Por un lado, genera perfiles de estrés moderado que amplían el soporte de entrenamiento respecto de la demanda histórica base. Por otro, produce episodios de cola extrema con mayor probabilidad de bloqueo de intersección, propagación de congestión o pérdida sensorial combinada. De este modo, la política no aprende exclusivamente sobre trayectorias medias, sino sobre distribuciones con colas relevantes para la gestión de riesgo sistémico.

4.3.2. Configuración del Agente RL Ligero

El núcleo algorítmico del sistema se implementa mediante *Proximal Policy Optimization* (PPO), seleccionado por su estabilidad empírica, su desempeño consistente en espacios de acción discretos y su facilidad para integrarse a entornos vectorizados. Dado que el espacio de observación es un vector unidimensional de baja a mediana dimensión, la arquitectura elegida para política y función de valor es un Perceptrón Multicapa, concretamente la política `MlpPolicy` disponible en `stable-baselines3`. Esta decisión evita complejidad innecesaria y se alinea con el objetivo de desarrollar una solución metodológicamente sólida y computacionalmente austera.

En términos de infraestructura, se fuerza explícitamente la inferencia sobre CPU. Esta elección no obedece a una limitación accidental, sino a una consideración de ingeniería. Para tensores pequeños y decisiones rápidas, la sobrecarga asociada a transferencias entre memoria principal y GPU puede degradar la eficiencia total del sistema, especialmente en entornos donde el despliegue final no contará con aceleradores especializados. En contraste, la CPU ofrece latencias estables y mayor afinidad con esquemas de *edge computing*, condición relevante para controladores semafóricos reales desplegados en gabinetes o centros de control con recursos restringidos (Guo et al., 2023).

El espacio de acción se define como un conjunto discreto:

$$\mathcal{A} = \{0, 1, 2, 3\},$$

donde cada acción representa una configuración verde predominante compatible con el plan de fases de la intersección. Las transiciones entre acciones no se aplican de forma instantánea e irrestricta; se incorporan tiempos de ámbar y despeje para garantizar seguridad y realismo ope-

racional. Así, el agente decide sobre configuraciones admisibles, mientras que el entorno impone las restricciones físicas y normativas mínimas requeridas para evitar cambios inviables.

El comportamiento del agente se modela mediante una función de recompensa que evita el utilitarismo clásico centrado exclusivamente en demora agregada. La recompensa instantánea se define como:

$$R_t = - \left(\lambda_1 \sum_{i=1}^n w_{i,t} \right) - \lambda_2 Gini_t - \lambda_3 CVaR_\alpha(L_t),$$

donde $w_{i,t}$ es el tiempo de espera asociado al carril o acceso i en el instante t , $Gini_t$ mide desigualdad distributiva del servicio y $CVaR_\alpha(L_t)$ penaliza pérdidas extremas asociadas al nivel de congestión o longitud de cola agregada. Los coeficientes $\lambda_j > 0$ regulan el peso relativo de cada término y se ajustan experimentalmente para evitar que una dimensión anule a las demás.

El componente de equidad se estima mediante el índice de Gini:

$$Gini_t = \frac{\sum_{i=1}^n \sum_{j=1}^n |w_{i,t} - w_{j,t}|}{2n^2 \bar{w}_t},$$

donde $\bar{w}_t$ es la espera media sobre el conjunto de accesos considerados. Esta formulación penaliza distribuciones altamente desiguales del servicio incluso cuando la demora promedio global parece aceptable. En consecuencia, el agente aprende no solo a reducir costo agregado, sino también a contener la concentración sistemática del perjuicio sobre movimientos secundarios o accesos periféricos, en línea con la evidencia de enfoques de control sensibles a justicia distributiva (Chen et al., 2021).

El término de riesgo se incorpora mediante $CVaR_\alpha$, utilizado como medida de cola para penalizar episodios donde la pérdida excede un umbral operacional severo. En lugar de optimizar únicamente el valor esperado de la congestión, la política internaliza la severidad de los peores casos plausibles. Esta decisión es especialmente relevante en contextos urbanos donde el colapso local puede propagarse espacialmente y generar efectos en cascada sobre nodos vecinos. Bajo este diseño, una política con gran rendimiento promedio pero con alta fragilidad frente a episodios extremos resulta metodológicamente inferior a una política algo menos eficiente en promedio pero notablemente más estable ante estrés.

4.3.3. Integración del Módulo de Transferencia Interregional

Un desafío central del control semafórico basado en aprendizaje es la transferencia de políticas más allá del entorno de entrenamiento inmediato. Para atender esta limitación, el *framework* incorpora un módulo de transferencia interregional orientado a evaluar la capacidad de adaptación *zero-shot* o con ajuste mínimo sobre configuraciones topológicas y distribuciones de demanda distintas de las observadas durante el aprendizaje base. El objetivo de esta capa no es solo medir precisión predictiva fuera de muestra, sino valorar hasta qué punto la política conserva regularidades de decisión útiles cuando cambia el contexto operativo.

Metodológicamente, esta integración se implementa exponiendo la política entrenada a entornos con variaciones controladas en geometría de accesos, intensidad de arribos, asimetrías direccionales y nivel de perturbación. La evaluación registra degradación relativa de métricas técnicas, de equidad y de riesgo respecto del dominio original. Este procedimiento permite distinguir entre tres tipos de comportamiento: políticas que generalizan razonablemente, políticas que requieren recalibración ligera y políticas fuertemente dependientes del entorno fuente.

La transferencia interregional cumple además una función estratégica dentro de la tesis. Si el sistema pretende ser viable para ciudades con infraestructura heterogénea, no basta con reportar buen rendimiento en un único nodo cuidadosamente calibrado. Es necesario demostrar que la representación del estado, la función de recompensa y el esquema de entrenamiento inducen un comportamiento con cierto grado de invariancia estructural. En este sentido, la evaluación de transferencia no se concibe como un experimento accesorio, sino como parte del criterio de validez externa del *framework* (Wang et al., 2021; Guo et al., 2023).

4.4. Diseño Experimental

4.4.1. Escenarios de Validación

El diseño experimental se organiza a partir de escenarios que combinan demanda heterogénea, perturbaciones operativas y perfiles de conducción no ideales. En lugar de evaluar el agente únicamente en condiciones promedio, se construyen dos familias principales de validación orientadas a tensionar distintos componentes del sistema.

El **Perfil 1: Conducción Anómala** introduce aceleraciones atípicas, tiempos de reacción heterogéneos, aceptación irregular de brechas e incumplimiento parcial de fase. Este escenario busca representar fricción conductual recurrente en contextos donde la obediencia semafórica y la disciplina vehicular no pueden asumirse como perfectas. Su incorporación es crucial para analizar si la política aprendida depende excesivamente de un régimen de tráfico ordenado o si, por el contrario, conserva estabilidad cuando la interacción entre vehículos se vuelve más errática.

El **Perfil 2: Eventos Exógenos** modela aumentos súbitos de demanda, paso prioritario de vehículos de emergencia, pérdidas parciales de sentido e incidencias localizadas que reducen capacidad de descarga. Este perfil reproduce perturbaciones de baja frecuencia pero alto impacto, especialmente relevantes para evaluar riesgo de cola y propagación de *spillback*. La comparación entre desempeño nominal y desempeño bajo eventos exógenos permite medir resiliencia operativa y sensibilidad del sistema a cambios abruptos del entorno (Guo et al., 2023; Wang et al., 2021).

En ambos perfiles, los escenarios se instancian sobre múltiples semillas aleatorias y sobre distintos archivos de enrutamiento para evitar conclusiones dependientes de una única trayectoria de simulación. Este procedimiento produce una base experimental más robusta y facilita el análisis posterior de variabilidad, intervalos de confianza y significancia estadística.

4.4.2. Protocolo de Entrenamiento y Paralelización

El entrenamiento principal se ejecuta durante 500,000 *timesteps*, cantidad suficiente para observar convergencia funcional de la política sin incurrir en costos experimentales desproporcionados. Con el fin de acelerar la recolección de experiencia, se emplea vectorización asíncrona mediante `SubprocVecEnv`, permitiendo que múltiples instancias del entorno generen trayectorias en paralelo. Esta decisión reduce el tiempo total de entrenamiento y mejora la diversidad de experiencias procesadas por el agente en cada ventana de actualización.

La ejecución paralela de SUMO introduce, sin embargo, un problema técnico conocido: las colisiones de puertos TCP y los conflictos entre conexiones TraCI concurrentes. Para resolverlo, la metodología implementa un protocolo de aislamiento por instancia. La inicialización del simulador delega la asignación de puertos a un mecanismo dinámico de búsqueda libre, equivalente a `getFreeSocketPort()`, mientras que cada cliente TraCI recibe un identificador único basado en UUID. Con ello se evita que dos procesos intenten abrir o reutilizar el mismo canal de comunicación, minimizando *race conditions* y errores intermitentes difíciles de reproducir.

El ciclo de entrenamiento sigue la lógica estándar de PPO: recolección de trayectorias, estimación de ventajas, actualización por minibatches y recorte proximal de la política para estabilizar el cambio de parámetros entre iteraciones. Durante este proceso se registran, además del retorno acumulado, métricas auxiliares de demora, cola, desigualdad y riesgo. La monitorización continua de estas señales es importante porque una mejora del retorno agregado no garantiza, por sí sola, que la política esté aprendiendo comportamientos deseables respecto de los objetivos sustantivos de la tesis.

Como criterio operativo, el entrenamiento se detiene al completar el presupuesto prefijado de interacciones y se reserva un conjunto separado de episodios para validación. La comparación entre desempeño durante entrenamiento y desempeño en validación permite detectar sobreajuste al conjunto de escenarios observados y verificar si las mejoras del agente se sostienen cuando enfrenta trayectorias no utilizadas para actualización de parámetros.

4.5. Métricas de Evaluación

4.5.1. Rendimiento Técnico

La eficiencia global del sistema se cuantifica mediante un conjunto de métricas técnicas clásicas en control de tráfico. En primer lugar, se mide el **tiempo medio de viaje**, que resume la experiencia integral del vehículo sobre la red o sobre el subcorredor analizado. En segundo lugar, se calcula la **demora promedio por vehículo**, útil para evaluar cuánto se desvía el sistema respecto de una circulación libre de congestión. En tercer lugar, se registra la **longitud máxima de cola**, métrica especialmente sensible a estados de saturación y potencial bloqueo de intersecciones. Finalmente, se considera el **throughput** total, entendido como el número de vehículos efectivamente servidos

o evacuados por el sistema durante la ventana de simulación.

Estas métricas permiten comparar el desempeño del agente con líneas base ampliamente utilizadas y facilitan la lectura ingenieril del resultado. No obstante, por sí mismas resultan insuficientes para responder a la pregunta central de la tesis. Una política puede mejorar throughput o demora media y, aun así, amplificar desigualdad entre accesos o aumentar la probabilidad de colapso bajo eventos severos. Por ello, el análisis técnico se complementa necesariamente con medidas de equidad y robustez.

4.5.2. Equidad Algorítmica y Robustez

La evaluación ampliada del sistema incorpora dos dimensiones prioritarias: equidad distributiva y resiliencia frente a pérdidas extremas. La **equidad distributiva** se monitoriza mediante el índice de Gini calculado iterativamente sobre tiempos de espera o demoras por acceso. Valores bajos del índice indican una distribución más balanceada del costo temporal; valores altos evidencian concentración del perjuicio en subconjuntos específicos de movimientos. Esta métrica es consistente con el diseño de la recompensa y permite verificar si la política aprendida efectivamente reduce sesgos distributivos o si tales mejoras son solo aparentes a nivel agregado (Chen et al., 2021).

La **robustez y el riesgo de cola** se evalúan mediante la desviación estándar de las demoras, la frecuencia de episodios con colas por encima de umbrales críticos y el cálculo de $CVaR_\alpha$ sobre una variable de pérdida operacional L_t . Esta pérdida puede definirse en función de cola total, demora acumulada o combinación ponderada de ambas, dependiendo del experimento específico. El uso de $CVaR_\alpha$ permite cuantificar no solo la magnitud promedio de la congestión, sino la severidad esperada condicionada a estar en la cola peor del comportamiento observado. Desde el punto de vista de la gestión urbana, esta es una medida más informativa que el promedio cuando interesa evitar estados de saturación extrema o propagación de *spillback*.

En conjunto, estas métricas conforman un marco de evaluación coherente con la lógica multiobjetivo del estudio. El controlador se considera superior no cuando maximiza una sola variable, sino cuando logra un compromiso favorable entre eficiencia, estabilidad y justicia operacional.

4.6. Herramientas y Configuración de Software

El *framework* se desarrolla íntegramente sobre un ecosistema de código abierto orientado a reproducibilidad experimental. La orquestación principal se implementa en Python 3.x, utilizado como lenguaje de integración entre simulación, modelado probabilístico, entrenamiento por refuerzo y análisis de resultados. La dinámica vehicular y el control microscópico de la red se ejecutan mediante SUMO (*Simulation of Urban MObility*), mientras que la interacción programática con el simulador se realiza a través de la interfaz TraCI.

El componente de aprendizaje profundo se implementa con PyTorch y la librería **stable-baselines3**, elegida por su estabilidad, mantenimiento activo y compatibilidad con PPO, entornos vectorizados y *callbacks* personalizados. Para la monitorización de entrenamiento se utiliza TensorBoard, integrando registros específicos de retorno, demora, cola, índice de Gini y métricas de riesgo. Esta monitorización en tiempo real permite detectar inestabilidades tempranas, divergencias del aprendizaje o compromisos no deseados entre objetivos.

Desde el punto de vista de configuración, el sistema prioriza reproducibilidad mediante fijación de semillas pseudoaleatorias, parametrización explícita del entorno y separación entre scripts de entrenamiento, validación y análisis. Asimismo, la decisión de ejecutar inferencia sobre CPU y de utilizar estados agregados de baja dimensionalidad reduce los requisitos de hardware y mejora la compatibilidad con despliegues en infraestructura urbana progresiva, donde el acceso a aceleradores de cómputo especializados suele ser limitado.

4.7. Diagrama de Flujo del Sistema

El proceso metodológico iterativo puede representarse como una secuencia de ocho bloques funcionales. Primero, la red de tráfico se instancia en SUMO junto con el archivo de demanda seleccionado para el episodio. Segundo, el módulo de generación de escenarios modifica o condiciona variables relevantes mediante la capa probabilística de *Vine Copulas*. Tercero, la simulación evoluciona durante el intervalo de decisión y produce telemetría cruda del sistema. Cuarto, dicha telemetría se transforma en el estado estructurado s_t . Quinto, el agente PPO procesa ese vector y estima la distribución de probabilidad sobre las acciones disponibles. Sexto, se selecciona una acción discreta admisible y se aplica al controlador semafórico mediante TraCI. Séptimo, el entorno calcula la recompensa instantánea penalizando ineficiencia, desigualdad y riesgo extremo. Octavo, la transición obtenida se almacena para la actualización de la política y el ciclo vuelve a comenzar.

Conceptualmente, el diagrama de flujo muestra que el sistema no está compuesto por módulos independientes que operan en serie sin retroalimentación, sino por un circuito cerrado donde simulación, modelado probabilístico y aprendizaje se condicionan mutuamente. La salida del módulo de copulas afecta el entorno; el entorno afecta la observación; la observación afecta la política; y la política modifica de nuevo el entorno a través del control semafórico. Esta representación es importante porque ilustra que la robustez buscada emerge de la interacción entre capas, no de un componente aislado.

4.8. Protocolo de Validación Estadística

La validación empírica se realiza mediante comparación sistemática contra tres líneas base metodológicas: (i) un controlador estático pretemporizado, (ii) un esquema actuado tradicional y

(iii) un agente RL entrenado únicamente para maximizar retorno esperado sin penalización explícita por inequidad ni riesgo extremo. Esta selección permite evaluar de forma gradual el valor añadido de cada componente del *framework*: adaptación, sensibilidad distributiva y control de cola.

Cada configuración experimental se ejecuta sobre múltiples episodios y semillas, registrando la distribución de resultados para todas las métricas principales. Sobre esta base se construyen intervalos de confianza y se aplican pruebas de significancia apropiadas para comparar medias o medianas según la forma empírica de los datos. Cuando los supuestos de normalidad y homocedasticidad resultan razonables, se emplean contrastes paramétricos; en caso contrario, se recurre a alternativas no paramétricas. Adicionalmente, se reportan tamaños de efecto para evitar interpretaciones basadas únicamente en significancia estadística.

El protocolo incorpora una segunda dimensión de validación: análisis de estabilidad entre escenarios. No basta con que el controlador supere a las líneas base en promedio; también debe mostrar variabilidad controlada entre perfiles de estrés y degradación razonable al cambiar de dominio. Por ello, los resultados se presentan tanto en forma agregada como desagregada por escenario, permitiendo identificar si la mejora se sostiene de manera consistente o si depende de condiciones experimentales demasiado específicas.

4.9. Consideraciones Éticas

La metodología integra consideraciones éticas desde el diseño del objetivo de optimización y no como una evaluación externa posterior. Esta decisión parte del reconocimiento de que un controlador puramente utilitarista puede reducir la demora total del sistema a costa de concentrar el costo de congestión en accesos periféricos, movimientos minoritarios o usuarios con menor capacidad de adaptación. En entornos urbanos reales, tal concentración no constituye un efecto colateral trivial, sino una forma de inequidad operacional con consecuencias sociales y territoriales relevantes.

La incorporación explícita del índice de Gini en la función de recompensa busca mitigar ese riesgo. En lugar de asumir que toda mejora agregada es socialmente deseable, el *framework* penaliza distribuciones excesivamente desiguales de espera, obligando al agente a internalizar la legitimidad distributiva de sus decisiones. De este modo, la inteligencia artificial se orienta a gestionar el sistema de forma más balanceada, no a imponer una lógica punitiva sobre los usuarios ni a reforzar sesgos preexistentes del entorno.

También existe una dimensión ética asociada a la robustez. Un sistema frágil frente a eventos extremos puede afectar con mayor intensidad a sectores ya vulnerables de la red, por ejemplo corredores con alta dependencia de transporte público o zonas con pocas rutas alternativas. Por ello, la penalización por riesgo de cola no solo cumple una función técnica de estabilización, sino también una función normativa mínima: reducir la probabilidad de colapsos severos cuyo impacto

tiende a distribuirse de forma desigual.

Finalmente, el carácter simulado del estudio evita el uso de datos personales sensibles y elimina riesgos directos sobre usuarios reales durante la etapa experimental. No obstante, la tesis reconoce que cualquier despliegue futuro requerirá auditoría contextual, calibración local y evaluación institucional adicional antes de una implementación operativa.

4.10. Conclusión Metodológica

La metodología desarrollada en este capítulo articula de forma coherente tres componentes centrales: modelado probabilístico de dependencias mediante *Vine Copulas*, aprendizaje por refuerzo profundo con PPO y optimización sensible a riesgo y equidad. Lejos de constituir módulos superpuestos de manera aditiva, estos componentes configuran una arquitectura unificada diseñada para enfrentar la brecha entre simulación idealizada y operación urbana realista.

Desde el punto de vista experimental, el uso de una red compleja, múltiples archivos de demanda, escenarios adversos, entrenamiento paralelo y protocolos de validación estadística proporciona una base robusta para evaluar el sistema con rigor. Desde el punto de vista algorítmico, la representación compacta del estado, la selección de una política ligera y la ejecución sobre CPU favorecen transferibilidad y viabilidad computacional. Desde el punto de vista sustantivo, la inclusión conjunta de demora, Gini y *CVaR* en la recompensa alinea el aprendizaje con una noción de desempeño más adecuada para sistemas urbanos complejos.

En consecuencia, el capítulo establece el soporte metodológico necesario para desarrollar y evaluar un controlador semafórico eficiente, escalable y distributivamente más justo. Sobre esta base, el capítulo siguiente presentará los resultados empíricos obtenidos, contrastando el desempeño del *framework* propuesto frente a líneas base convencionales en condiciones nominales y de estrés.

Capítulo 5

Resultados y Discusión

5.1. Configuración Experimental

Presenta las condiciones finales bajo las cuales se obtuvieron los resultados.

5.2. Evaluación del Módulo de Generación de Escenarios

Incluye tablas, figuras y análisis cuantitativo del primer componente.

5.3. Evaluación del Módulo de Decisión o Control

Muestra resultados asociados al segundo componente o proceso principal.

5.4. Evaluación del Módulo de Equidad o Robustez

Analiza el desempeño respecto a criterios éticos o de estabilidad.

5.5. Comparativa con Modelos Tradicionales

Contrasta los resultados con líneas base, métodos clásicos o trabajos previos.

5.6. Análisis Estadístico y Robustez

Reporta pruebas estadísticas y discute la consistencia de los hallazgos.

5.7. Discusión de Resultados

Interpreta el significado de los resultados y relacionalos con los objetivos e hipótesis.

5.8. Limitaciones

Identifica las principales limitaciones metodológicas, empíricas o computacionales.

5.9. Conclusión del Capítulo

Resume los aportes empíricos más importantes del capítulo.

Capítulo 6

Discusión

6.1. Interpretación de los Resultados Clave

Profundiza en el valor científico de los hallazgos más relevantes.

6.2. Comparación con el Estado del Arte

6.2.1. Ventajas sobre Métodos Existentes

Explica en qué supera tu propuesta a trabajos anteriores.

6.2.2. Limitaciones Persistentes

Señala qué problemas siguen abiertos pese a los avances obtenidos.

6.3. Implicaciones Teóricas y Prácticas

6.3.1. Contribuciones al Campo

Describe las contribuciones conceptuales o metodológicas.

6.3.2. Impacto Aplicado o Socioeconómico

Discute la transferencia potencial del trabajo a contextos reales.

6.4. Limitaciones y Sesgos

6.4.1. Dependencia de Datos o Supuestos

Explica restricciones derivadas del diseño experimental o del conjunto de datos.

6.4.2. Sesgos en Perfiles, Muestras o Anotaciones

Describe sesgos potenciales y su efecto en la validez de la tesis.

6.5. Lecciones Aprendidas

Sintetiza aprendizajes metodológicos y prácticos del proceso doctoral.

6.6. Recomendaciones para Políticas Públicas o Implementación

Formula recomendaciones concretas para adopción institucional, industrial o social.

6.7. Futuras Líneas de Investigación

Identifica extensiones prometedoras de la tesis.

6.8. Conclusión Final

Cierra el capítulo con una valoración integral del alcance del trabajo.

Capítulo 7

Conclusiones y Trabajo Futuro

7.1. Síntesis de Contribuciones Clave

Enumera las principales aportaciones originales de la tesis.

7.2. Cumplimiento de Objetivos e Hipótesis

Contrasta resultados obtenidos con objetivos e hipótesis iniciales.

7.3. Limitaciones y Desafíos

Resume las barreras identificadas y su impacto en la generalización del trabajo.

7.4. Recomendaciones para Implementación Práctica

Propón pasos concretos para la adopción o transferencia del modelo, método o sistema.

7.5. Trabajo Futuro

Describe nuevas líneas de investigación, mejoras técnicas o validaciones pendientes.

7.6. Reflexión Final

Incluye un cierre académico y personal sobre el valor global de la investigación.

Bibliografía

- Asad Ali, Jianjun Huang, Ayesha Jabbar, Mubashir Ali, and Sijjad Ali. Federated learning for connected autonomous vehicles: enhancing mobility, safety, and sustainability. *PHYSICA SCRIPTA*, 100(7), JUL 1 2025. ISSN 0031-8949. doi: 10.1088/1402-4896/addca2.
- Elarbi Badidi, Karima Moumane, and Firdaous El Ghazi. Opportunities, applications, and challenges of edge-ai enabled video analytics in smart cities: A systematic review. *IEEE ACCESS*, 11:80543–80572, 2023. ISSN 2169-3536. doi: 10.1109/ACCESS.2023.3300658.
- Doha Bakir, Khalid Moussaid, Zouhair Chiba, and Noredine Abghour. A comprehensive review of traffic congestion prediction models: Machine learning and statistical approaches. In *2024 IEEE International Conference on Computing (ICOCO)*, pages 539–545, 2024. doi: 10.1109/ICOCO62848.2024.10928197.
- Igor Bisio, Chiara Garibotto, Halar Haleem, Fabio Lavagetto, and Andrea Sciarrone. A systematic review of drone based road traffic monitoring system. *IEEE ACCESS*, 10:101537–101555, 2022. ISSN 2169-3536. doi: 10.1109/ACCESS.2022.3207282.
- J Chen, Z Zhang, J Feng, and K Zhu. Fit: Fairness-aware intelligent traffic signal control with deep reinforcement learning. In *2021 IEEE 23rd Int Conf on High Performance Computing & Communications; 7th Int Conf on Data Science & Systems; 19th Int Conf on Smart City; 7th Int Conf on Dependability in Sensor, Cloud & Big Data Systems & Application (HPCC/DSS/SmartCity/DependSys)*, pages 846–852. IEEE, 2021. doi: 10.1109/HPCC-DSS-SmartCity-DependSys53884.2021.00136.
- Haipeng Cui, Qiang Meng, Teck-Hou Teng, and Xiaobo Yang. Spatiotemporal correlation modelling for machine learning-based traffic state predictions: state-of-the-art and beyond. *TRANSPORT REVIEWS*, 43(4):780–804, JUL 4 2023. ISSN 0144-1647. doi: 10.1080/01441647.2023.2171151.
- Qimei Cui, Xingxing Hu, Wei Ni, Xiaofeng Tao, Ping Zhang, Tao Chen, Kwang-Cheng Chen, and Martin Haenggi. Vehicular mobility patterns and their applications to internet-of-vehicles: a comprehensive survey. *SCIENCE CHINA-INFORMATION SCIENCES*, 65(11), NOV 2022. ISSN 1674-733X. doi: 10.1007/s11432-021-3487-x.
- Zekuan Fang, Fan Zhang, Ting Wang, Xiang Lian, and Mingsong Chen. Monitorlight: Reinforcement learning-based traffic signal control using mixed pressure monitoring. In *International*

- Conference on Information and Knowledge Management, Proceedings*, pages 478–487. Association for Computing Machinery, 10 2022. ISBN 9781450392365. doi: 10.1145/3511808.3557400.
- Carmen Gheorghe and Adrian Soica. Revolutionizing urban mobility: A systematic review of ai, iot, and predictive analytics in adaptive traffic control systems for road networks. *ELECTRONICS*, 14(4), FEB 2025. ISSN 2079-9292. doi: 10.3390/electronics14040719.
- Artur Grigorev, Adriana-Simona Mihaita, and Fang Chen. Traffic incident duration prediction: A systematic review of techniques. *JOURNAL OF ADVANCED TRANSPORTATION*, 2024 (1), 2024. ISSN 0197-6729. doi: 10.1155/atr/3748345.
- Jiaying Guo, Saeedeh Ghanadbashi, Shen Wang, and Fatemeh Golpayegani. Urban traffic signal control at the edge: An ontology-enhanced deep reinforcement learning approach. In *IEEE Conference on Intelligent Transportation Systems, Proceedings, ITSC*, pages 6027–6033. Institute of Electrical and Electronics Engineers Inc., 2023. ISBN 9798350399462. doi: 10.1109/ITSC57777.2023.10422573.
- Yu Han, Meng Wang, and Ludovic Leclercq. Leveraging reinforcement learning for dynamic traffic control: A survey and challenges for field implementation. *Communications in Transportation Research*, 3, 2023. doi: 10.1016/j.commtr.2023.100104.
- Yash Jain and Kavita Pandey. Transforming urban mobility: A systematic review of ai-based traffic optimization techniques. *ARCHIVES OF COMPUTATIONAL METHODS IN ENGINEERING*, 2025 JUN 13 2025. ISSN 1134-3060. doi: 10.1007/s11831-025-10297-6.
- Renhe Jiang, Du Yin, Zhaonan Wang, Yizhuo Wang, Jiewen Deng, Hangchen Liu, Zekun Cai, Jinliang Deng, Xuan Song, and Ryosuke Shibasaki. Dl-traff: Survey and benchmark of deep learning models for urban traffic prediction. pages 4515 – 4525, 2021. doi: 10.1145/3459637.3482000.
- Yuqi Liu, Qichao Zhang, and Dongbin Zhao. A brief survey of deep reinforcement learning for intersection navigation of autonomous vehicles. pages 1844 – 1851, 2024. doi: 10.1109/DDCLS61622.2024.10606719.
- Harshit Maheshwari, Li Yang, and Richard W. Pazzi. Machine learning advancements in urban traffic simulation: A comprehensive survey. *IEEE Open Journal of Intelligent Transportation Systems*, 6:1027–1052, 2025. doi: 10.1109/OJITS.2025.3589208.
- Wei Miao, Long Li, and Zhiwen Wang. A survey on deep reinforcement learning for traffic signal control. pages 1092 – 1097, 2021. doi: 10.1109/CCDC52312.2021.9601529.
- Mohammad Noaen, Atharva Naik, Liana Goodman, Jared Crebo, Taimoor Abrar, Zahra Shakeri Hossein Abad, A. L. C. Bazzan, and Behrouz Homayoun Far. Reinforcement learning in urban network traffic signal control: A systematic literature review. *Expert Systems with Applications*, 199, 2022. doi: 10.1016/j.eswa.2022.116830.
- Mohammad Noroozi, Hanieh Rastegar Moghaddam, Ankit Shah, Hadi Charkhgard, Sudeep Sarkar, Tapas K. Das, and Timothy Pohland. An ai-assisted systematic literature review of the

- impact of vehicle automation on energy consumption. *IEEE TRANSACTIONS ON INTELLIGENT VEHICLES*, 8(6):3572–3592, JUN 2023. ISSN 2379-8858. doi: 10.1109/TIV.2023.3268300.
- Ekene F. Ozioko, Julian Kunkel, and Fredric Stahl. Road intersection coordination scheme for mixed traffic (human driven and driver-less vehicles): A systematic review. In *INTELLIGENT COMPUTING, VOL 3*, volume 508 of *Lecture Notes in Networks and Systems*, pages 67–94, 2022. ISBN 978-3-031-10467-1. doi: 10.1007/978-3-031-10467-1_4.
- R. Anto Pravin and Nancy Noella R S. Review on traffic prediction framework using machine and deep learning algorithms. In *2025 International Conference on Intelligent Computing and Control Systems (ICICCS)*, pages 684–691, 2025. doi: 10.1109/ICICCS65191.2025.10984630.
- Noor Afiza Mat Razali, Nuraini Shamsaimon, Khairul Khalil Ishak, Suzaimah Ramli, Mohd Fahmi Mohamad Amran, and Sazali Sukardi. Gap, techniques and evaluation: traffic flow prediction using machine learning and deep learning. *JOURNAL OF BIG DATA*, 8(1), DEC 4 2021. ISSN 2196-1115. doi: 10.1186/s40537-021-00542-7.
- Rui Rong, Shoufeng Ma, Nianlu Ren, Qinqing Lin, and Ning Jia. Generative artificial intelligence in intelligent transportation systems: A systematic review of applications. *FRONTIERS OF ENGINEERING MANAGEMENT*, 2025 APR 28 2025. ISSN 2095-7513. doi: 10.1007/s42524-025-4241-9.
- Anant Saini and Jyoti Srivastava. A survey on real-time traffic signal optimization using deep learning and vehicle tracking. pages 1330 – 1337, 2025. doi: 10.1109/ICICV64824.2025.11085920.
- Lincoln V. Schreiber, Lucas N. Alegre, Ana L.C. Bazzan, and Gabriel De O. Ramos. On the explainability and expressiveness of function approximation methods in rl-based traffic signal control. In *Proceedings of the International Joint Conference on Neural Networks*. Institute of Electrical and Electronics Engineers Inc., 2022. ISBN 9781728186719. doi: 10.1109/IJCNN55064.2022.9892422.
- Qinbatu Si, Lirun Yang, Jingjing Bao, Yangfei Lin, Wugede Bao, and Celimuge Wu. A survey on deep learning-based traffic signal control. *Journal of Circuits, Systems and Computers*, 34 (2), 2025. doi: 10.1142/S0218126625300016.
- Deepika Sirohi, Neeraj Kumar, and Prashant Singh Rana. Convolutional neural networks for 5g-enabled intelligent transportation system : A systematic review. *COMPUTER COMMUNICATIONS*, 153:459–498, MAR 1 2020. ISSN 0140-3664. doi: 10.1016/j.comcom.2020.01.058.
- K. Thamaraiselvi, Asha Rani Bohra, V. Vishal, Pawan Sai Sunkara, Balaji Sunku, and Bhavsar Nityajignesh. Exploring traffic signal control: A comprehensive survey on reinforcement learning techniques. 2025. doi: 10.1109/ICIDeA64800.2025.10963194.
- Bohdan Vihurskyi. Optimizing urban traffic management with machine learning techniques: A systematic review. In *2024 2nd International Conference on Advancement in Computation &*

Computer Technologies (InCACCT), pages 403–408, 2024. doi: 10.1109/InCACCT61598.2024.10551137.

Sriharsha Vikruthi, Maruthavanan S. Archana, and Rama Chaithanya Tanguturi. A survey on deep learning based vehicular traffic control systems. volume 2512, 2024. doi: 10.1063/5.0111949.

Xiaoqiang Wang, Liangjun Ke, Zhimin Qiao, and Xinghua Chai. Large-scale traffic signal control using a novel multiagent reinforcement learning. *IEEE Transactions on Cybernetics*, 51:174–187, 1 2021. ISSN 21682275. doi: 10.1109/TCYB.2020.3015811.

Kaiwen Zhang, Zhiyong Cui, and Wanjing Ma. A survey on reinforcement learning-based control for signalized intersections with connected automated vehicles. *TRANSPORT REVIEWS*, 44 (6):1187–1208, NOV 1 2024. ISSN 0144-1647. doi: 10.1080/01441647.2024.2377637.

Haiyan Zhao, Chengcheng Dong, Jian Cao, and Qingkui Chen. A survey on deep reinforcement learning approaches for traffic signal control. *Engineering Applications of Artificial Intelligence*, 133, 2024. doi: 10.1016/j.engappai.2024.108100.

Apéndice A

Anexos

A.1. Protocolo de Búsqueda y Cadenas de Consulta

Incluye aquí las bases de datos consultadas, criterios de inclusión y exclusión, y las cadenas de búsqueda utilizadas.

A.2. Matriz de Extracción SLR (Corpus Primario)

Presenta la matriz de extracción del corpus primario de estudios revisados.

A.3. Diagrama PRISMA 2020 (Fase 1 y Fase 2)

Incorpora el flujo de identificación, cribado, elegibilidad e inclusión de estudios.

A.4. Hiperparámetros y Configuración de Entrenamiento

Documenta la configuración experimental completa, semillas, hardware y parámetros finales.

A.5. Código Fuente y Repositorio Complementario

Añade aquí la referencia al repositorio, organización del código y materiales suplementarios.